

北京邮电大学

硕士研究生学位论文



题目： 协作过滤算法及其在
个性化推荐系统中的应用

学 号： 046333

姓 名： 鲁 为

专 业： 模式识别与智能系统

导 师： 王 枫

学 院： 信息工程学院

2007 年 3 月 12 日

北京邮电大学

硕士研究生学位论文



题目： 协作过滤算法及其在
个性化推荐系统中的应用

学 号： 046333

姓 名： 鲁 为

专 业： 模式识别与智能系统

导 师： 王 枏

学 院： 信息工程学院

2007 年 3 月 12 日

独创性（或创新性）声明

本人声明所呈交的论文是本人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢中所罗列的内容以外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京邮电大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

申请学位论文与资料若有不实之处，本人承担一切相关责任。

本人签名： 鲁为 日期： 07.3.30

关于论文使用授权的说明

学位论文作者完全了解北京邮电大学有关保留和使用学位论文的规定，即：研究生在校攻读学位期间论文工作的知识产权单位属北京邮电大学。学校有权保留并向国家有关部门或机构送交论文的复印件和磁盘，允许学位论文被查阅和借阅；学校可以公布学位论文的全部或部分内容，可以允许采用影印、缩印或其它复制手段保存、汇编学位论文。（保密的学位论文在解密后遵守此规定）

保密论文注释：本学位论文属于保密在__年解密后适用本授权书。非保密论文注释：本学位论文不属于保密范围，适用本授权书。

本人签名： 鲁为 日期： 07.3.30

导师签名： 27 日期： 07.3.30

协作过滤算法及其在个性化推荐系统中的应用

摘 要

随着 Internet 和电子商务技术的迅猛发展，信息膨胀与冗余给人们的生活和商务工作带来了信息选择的困惑。人们迫切需要一种个性化推荐技术帮助他们实现信息过滤和对服务的自动推荐。本文研究了个性化推荐系统及其主要的推荐技术，特别是协作过滤技术，包括基于用户的协作过滤技术和基于项目的协作过滤技术。

基于用户的协作过滤算法是目前应用最成功的一种个性化推荐技术，它在推荐效果和准确性等方面显示出了卓越的优势。但是，这种推荐技术中存在的稀疏问题和冷开始问题也严重影响了推荐系统的性能，使协作过滤的效果得不到充分的发挥。

在以上分析的基础上，本文的工作及创新主要体现在下面的三个方面：

1. 对用户-项目评价矩阵进行降维的预处理，验证了这种方法对原始评价矩阵降低了噪音，而且有效地揭示了矩阵用户之间的潜在关联性，有效地解决了稀疏问题。
2. 在用户间相似度的计算阶段，用实验充分验证了计算用户间相似度使用相关相似度的度量标准所得到的算法要比余弦相似度算法的推荐质量要高。
3. 在预测阶段，采用中心加权求和的方法预测用户对新项目的评分，并且通过实验验证了这种中心加权求和的方法比单纯用基于用户和基于项目的协作推荐算法具有更高的推荐质量，同时，这样很好地弥补了协作过滤算法在冷开始中的新项目问题上的不足，提高了推荐系统的推荐质量与推荐精度。

关键词 个性化推荐 协作过滤 相似度

STUDY OF RECOMMENDATION SYSTEM BASED ON COLLABORATIVE FILTERING ALGORITHM

ABSTRACT

With the popularization of Internet and the rapid development of E-commerce, many famous E-Commerce sites have developed Recommender system for providing personalization service to consumers. Recommender systems are used by E-commerce sites to suggest products their customers and to provide consumers with information to help them decide which products to purchase. This article researched the personalized recommender system and its main recommendation technologies, especailly collaborative filtering algorithm including User-based collaborative algorithm and Item-based collaborative algorithm. The expansion and redundance of information bring forth people the puzzle of choosing information.

Collaborative filtering algorithm has been very successful in both research and practice, especially in the effect and precision of recommendation. But it suffer from sparsity and cold-start problem which affect the performance of recommendation system badly, which could not take advantage of the Collaborative filtering.

Based on the analysis of these, the detail works is shown below:

1.Decomposition the user-item rating matrix, and validate that this method could reduce the noise of matrix and can open out the latent relevancy between users ,solving sparsity problem.

2.Computing the similarity between users, our experiment validate that the measurement of Correlation-based Similarity has more higher quality of recommendation than that of Cosine-based Similarity.

3.At the step of prediction, our experiment use the method of

Deviation-from-Mean to predict new item ratings that users have not rated and validate that this method has higher quality of recommendation than that of user-based and Item-based collaborative filtering algorithm. Meanwhile, it remedy the disadvantage of new-item in cold startup problem, increasing the quality and precision of recommendation.

KEY WORDS personalized recommendation, collaborative filtering method, similarity.

目 录

摘 要.....	3
ABSTRACT	4
目 录	6
第一章 绪 论	8
1.1 个性化推荐系统的研究综述	8
1.1.1 个性化推荐系统的研究背景	8
1.1.2 个性化推荐系统的发展	9
1.1.3 个性化推荐系统的研究意义	10
1.1.4 国内外研究现状	11
1.2 本文的研究对象和工作	12
1.3 论文的结构安排	12
1.4 小结	12
第二章 个性化推荐系统及其核心技术	13
2.1 个性化推荐系统概述	13
2.1.1 个性化推荐系统的概念	13
2.1.2 个性化推荐系统的研究内容	14
2.1.3 个性化推荐系统的经济效益	15
2.1.4 个性化推荐系统的类别	16
2.2 个性化推荐系统的结构	16
2.2.1 推荐系统的图形化用户界面	17
2.2.2 个性化推荐系统的输入	18
2.2.3 个性化推荐系统的推荐形式	19
2.3 主要的个性化推荐技术	20
2.4 组合推荐技术	21
2.5 协作过滤算法	22
2.5.1 协作过滤算法的思路及过程	23
2.5.2 协作过滤算法的分类	25
2.6 小结	28
第三章 基于降维与项目评估预测的协作过滤算法	29
3.1 协作过滤推荐算法	29
3.1.1 User-based 协作过滤算法	29
3.1.2 Item-based 协作过滤算法	31
3.1.3 基于降维的协作过滤算法	33
3.2 优劣分析及其解决方法	35
3.2.1 稀疏问题 (Sparsity)	35
3.2.2 冷开始问题 (Cold-start)	36
3.2.3 优化的协作推荐算法的提出	37
3.3 优化的协作过滤算法	38
3.3.1 算法的流程图	40
3.3.2 对用户评价矩阵进行降维处理	40
3.3.3 寻找最近邻居	40

3.3.4 产生推荐	41
3.4 小结	42
第四章 实验设计和结果分析	43
4.1 推荐的实验数据	43
4.2 推荐的实验设计	43
4.2.1 评估标准	43
4.2.2 实验结果及分析	45
4.3 小结	47
第五章 总 结	48
5.1 本文的工作	48
5.2 进一步的工作	48
5.3 研究展望	49
参考文献	50
致 谢	54
攻读学位期间发表的学术论文发表的论文	55

第一章 绪 论

随着信息技术的日新月异和时代的发展，人们对信息个性化的要求越来越高，网络和电子商务日趋深入人们的生活，为了满足用户个性化服务的需求，个性化推荐系统应运而生。本章介绍个性化推荐系统的背景、发展和意义及国内外的研究现状，并说明本文的工作和结构安排。

1.1 个性化推荐系统的研究综述

1.1.1 个性化推荐系统的研究背景

Internet 的迅猛发展将人类带入了信息社会和网络经济时代，对个人生活和企业发展都产生了深远的影响。一方面，Internet 的发展正在极大的改变着每个人的生活，人们不出家门就可随心所欲的得到自己想要的商品，网上购物的经历让我们感受到电子商务带来的惊喜；另一方面，基于 Internet 的虚拟企业不再需要像传统的物理环境下企业那样的实体投资，企业与顾客、供应商等建立起了更直接的联系，电子商务模式为企业的发展提供了更多的机会。

截止到 2005 年电子商务活动的总价值已达到 7.5 亿元。但事实上，电子商务的应用还远没有被挖掘出来，这其中固然有硬件设施滞后、用户观念未改变等原因，而企业服务不到位更是一个重要的原因。电子商务的发展模式对企业服务提出了许多新的要求，包括商品的质量保证、送货及时、商品选购舒适、退货方便等。其中，最为突出的一个问题就是商品选购的个性化推荐问题。

由于供应链和物流的发展，在电子商务的虚拟环境下商家在网上所能提供的商品种类和数量非常繁多，但用户不可能通过一个小小的计算机屏幕方便的发现自己感兴趣的物品。用户既不愿意花太多时间在漫无边际的网上寻找商品，也不可能像在物理环境下那样检查商品的质量。在这样背景下，用户就急需电子商务系统提供一种类似采购助手的功能来帮助其选购商品，它能够根据用户的兴趣爱好自动地推荐给每个用户其可能感兴趣并且满意的商品，这样做的根本目的是使用户在这种虚拟购物环境下能够更方便、更容易地得到自己所需要的商品。

在这种背景下，推荐系统(recommender systems) 应运而生,它是根据用户的兴趣爱好, 推荐符合用户兴趣爱好的对象, 也称个性化推荐系统(personalized recommender systems) [1], 而协作过滤算法是其中的关键技术, 也是目前应用最广泛的一种个性化推荐的方法。

1.1.2 个性化推荐系统的发展

尽管关于信息过滤技术很早就有研究,但对协作过滤技术以及电子商务个性化推荐的研究只是近十几年的事。

协作过滤系统的研究最早始于 1992 年的 Tapestry[1],这是最早使用协作过滤推荐技术的推荐系统之一。该系统依赖于像办公小组之类的封闭团体内人们的直接观点,这是协作过滤推荐系统的最初尝试。但是,该系统存在着明显的问题——面向大型团体的推荐系统不能依赖于互相认识的人。

几年后,一些基于评分的自动化推荐系统应运而生,协作过滤的概念被广泛应用到商业企业。例如,GroupLens 调查系统[2,3]为 Usenet 新闻和电影提供匿名的协作过滤方案;Ringo[4]和 Video 推荐器[5]是分别生成音乐和电影的基于电子邮件和网络的系统;KACM 通信的一个专版提出了一些不同的推荐器。与此同时,一些其他的技术也被应用到了推荐系统中,包括 Bayesian 网络、聚类和萃取[7,8]。

此后,各种各样适用于个性化推荐系统的方法陆续开发出来,诸如利用人口统计学、内容或历史信息[2,4,5,9-11]。基于用户的协作过滤算法是建立推荐系统方面最成功和应用最广泛的技术[2,3]。对于每个用户,基于用户的协作过滤推荐系统利用历史信息,识别具有相似行为或偏好(如,访问相同类型的信息、购买相似的产品、喜欢/不喜欢相似的电影)的邻居用户,通过分析这些邻居用户来识别用户可能感兴趣的新信息。因此,这种方法也被称为基于邻居的协作过滤或最近邻居算法。

1996 年,学术界和商业界的研究人员聚会在 UC-Berkeley,共同探讨这种新兴的技术(Collaborative Filtering workshop, 1996),并对协作过滤给出了明确的定义,探讨了协作过滤算法的应用前景。1998 年 7 月各国学者聚会 Wisconsin,由美国 AAAI 组织,专门召开了 Workshop on Recommender Systems 会议,对推荐系统的发展进行了集中讨论。Resnick & Varian 在 1997 年给电子商务个性化推荐系统(Personalized Recommender Systems for E-Commerce)的正式定义为:“它是利用电子商务网站向客户提供商品信息和建议,帮助用户决定应该购买什么产品,模拟销售人员帮助客户完成购买过程”[6]现在这个定义已被广泛引用。

之后,Schafer 提出了个性化推荐系统的详细的分类和实例,以及它们如何提供一对一的个性化服务并且把握住用户的忠诚度。尽管这些系统已经在过去获得了成功,但是它们广泛的应用也揭示了其中的局限性,如数据集的稀疏问题和高维相关的问题等。文献[13,14]处理了推荐系统的稀疏问题,文献[15]讨论了推荐系统的和高维相关的问题,文献[16]研究了降维技术的应用。

目前,协作过滤推荐算法已被广泛应用到各行业中。对传统的协作过滤算法

中的稀疏问题和冷开始的研究也在逐渐发展，主要方法是组合推荐 Hybrid Recommendation，常用的是协作过滤和基于内容的推荐组合，如 Fab[9]通过分析用户评价的项目内容去建立基于内容的用户兴趣资料；GroupLens 研究小组用协作过滤组合其他用户的意见和个人信息过滤代理[13]；文献[10]把推荐当作一个分类任务，利用内容特征和协作特征组合推荐等[17-20]，但这方面的研究成果还十分有限。

1.1.3 个性化推荐系统的研究意义

个性化推荐系统是现代商务发展的产物，而协作过滤算法适应了对推荐系统的实际技术要求，所以研究个性化推荐系统中的协作过滤推荐具有重要意义。

社会的发展对研究个性化推荐系统提出了需要，信息时代的到来和电子商务的出现改变了人们的生活，人们对个性化服务和产品产生了迫切的需求。在电子商务的虚拟环境下，电子商务企业所能提供的商品种类和数量非常多，但是用户不希望也不可能浪费大量时间在网上寻找商品，这就需要个性化推荐系统提供个性化服务的功能把用户可能感兴趣的商品推荐给用户，使用户能够方便、容易的得到自己所需要的商品。从企业方面来说，要在激烈的市场竞争中赢得存在和发展，除了生产价廉物美的产品之外，还必须在产品营销上主动地把合适的产品送到合适的用户手中，为用户的网上购物提供便捷的个性化购物环境。因此，个性化推荐系统符合现代商务中用户个体、企业和社会的需要。

同时，研究个性化推荐系统对企业和社会具有很高的经济价值。顾客是利润的来源，谁能提供给顾客更好、更满意、更具个性化的产品和服务，谁就能赢得市场。应该看到，电子商务模式使用户从物理购物环境转向虚拟购物环境的同时，也对企业服务提出了许多更新、更高的要求，包括商品选购便捷、付款方便、质量保证、送货及时、退货容易等，其中首先遇到的一个重要问题就是如何满足不同顾客对不同商品的个性化需求，提供给顾客所需要的商品信息，以便顾客选购，而这正是企业价值链的源头和市场营销的起点。

在理论研究方面，个性化推荐系统具有较高的学术价值。自从 1992 年以来，个性化推荐系统和协作过滤推荐被国际学术界广泛关注，并逐渐被应用于各个行业。电子商务个性化推荐系统中的协作过滤推荐能对非结构化的复杂对象提供准确性较高的个性化推荐结果。但是传统的协作过滤推荐存在的冷开始和稀疏问题严重影响了推荐性能，成为国内外研究学者的研究焦点，人们逐渐认识到对个性化推荐系统中协作过滤推荐的研究在学术研究领域占有重要的地位。

1.1.4 国内外研究现状

个性化推荐系统是信息检索和信息过滤领域的研究热点,得到了许多著名研究机构和研究者的关注,出现了大型研究型推荐系统实例:

- **Amazon:** Amazon.com(亚马逊)是最大的网上书店,推出一种名为 Plog(Personalized Blog)的服务。Plog 是一种个性化的 blog,主要通过用户对用户们浏览过的商品和购物记录进行筛选,来给用户推荐的商品和相关的购物信息。它可以帮助用户发现新推出的商品和跟踪自己的订单。Plog 中的记录是按照时间的逆序进行排列的。而且 Plog 会随着用户访问 Amazon 次数的和交易数目的增加而变得更加有用和有趣。
- **EBay:** eBay 是世界最大的网上交易平台。eBay 使用用户反馈模型机制来促进买卖双方的交易。反馈包括一个满意度的评分(感到满意、一般或感到不满意)以及关于其它客户相关评述,系统根据反馈信息向用户提供推荐。反馈模型包括最近的 7 天、过去的一个月以及最近的 6 个月的用户评分;在需要的情况下,买方可以浏览只针对卖主的评分和评论。
- **GroupLens:** 由 MIT 开发的自动协作过滤推荐系统,用于新闻组信息推荐。GroupLens 系统通过用户的评分信息自动搜索用户的最近邻居,然后根据最近邻居的评分信息产生最终的推荐结果,适合于用户数量比较大的场合。GroupLens 系统具有极好的开放性,用户可以通过 GroupLens 系统提供的 API 函数向 GroupLens 服务器提供评分信息,请求推荐结果。同时, GroupLens 系统提供三种客户端工具 Emacs Gnus, NN 和 NewsWatcher 达到上述目的。
- **MovieLens:** 是 Minnesota 大学开发的研究型自动协作过滤推荐系统,用于推荐电影。与 GroupLens 不同,MovieLens 系统是一个基于 Web 的推荐系统,系统通过浏览器的方式进行用户评分数据收集与推荐结果显示,用户使用更加方便。
- **Video Recommender:** 是 Bellcore 开发的协作过滤推荐系统,用于电影推荐。Video Recommender 系统通过电子邮件的方式收集用户评分数据,提供推荐服务。在 Video Recommender 系统中,不仅可以预测用户最喜欢的电影,也可以预测用户对特定电影的评分。在 Video Recommender 系统提供推荐结果时,同时向用户提供用户最近邻居的电子邮件联系方式,以及用户与最近邻居的相似度等信息。
- **Ringo:** 由 MIT 媒体实验室开发的研究型协作过滤推荐系统,用于提供个性化的音乐推荐服务。Ringo 系统可以向用户推荐用户最喜欢的音乐,预测用户最不喜欢的音乐,也可以预测用户对特定音乐的评分。

1.2 本文的研究对象和工作

本文研究的对象是个性化推荐系统中的协作过滤算法，主要工作是研究传统的协作推荐算法中的冷开始和稀疏问题的解决方法。

试图采用基于降维的协作推荐算法从项目资料中挖掘用户之间的潜在的相关信息，并且从理论上分析了基于降维的预测方法比传统的相关相似性的预测方法在算法方面的时间复杂度和计算复杂度要优越，之后提出了一种优化协作过滤算法。首先对用户—项目评价矩阵根据项目之间的相似度初步预测用户对未评分项目的评分，并在此基础上通过实验来选取中心加权求和的相似度度量方法来计算目标用户的最近邻居；最后，利用用户的最近邻居集合，预测对每个项目的评分，从而推荐项目给目标用户。最后通过实验验证了所采用的降维的方法、相关相似度的度量方法与所采用的中心加权求和的预测方法的有效性与稳定性，这些方法的择优选择有效地弥补了传统协作过滤算法所出现的稀疏问题和冷开始问题，有效地提高了个性化推荐的推荐质量。

1.3 论文的结构安排

本文在第一章研究个性化推荐系统的背景和意义，并简要说明本文的主要工作；第二章介绍个性化推荐系统的概念、研究内容和主要的推荐技术，协作过滤算法的主要流程及其分类；第三章在分析协作过滤推荐和基于降维的协作推荐的特点之后，研究基于降维和项目评估预测的协作推荐算法，给出此算法的具体步骤；第四章进行优化协作推荐算法的仿真实验设计和结果分析；第五章总结实验结果，并对进一步的工作作出展望。

1.4 小结

本章介绍了个性化推荐系统的背景和推荐技术近几年的发展，强调了本文研究的意义，提出了研究的对象和工作，并对论文的结构安排进行了简要说明。

第二章 个性化推荐系统及其核心技术

个性化推荐系统是在电子商务过程中针对不同的用户提供个性化的产品和服务的应用系统。本章介绍个性化推荐系统的一些基本概念和研究内容，以及主要的个性化推荐技术。

2.1 个性化推荐系统概述

2.1.1 个性化推荐系统的概念

个性化推荐系统(Personalized Recommender Systems for E-Commerce)正式的定义是 Resnick & Varian 在 1997 年给出的：“它是利用电子商务网站向客户提供商品信息和建议，帮助用户决定应该购买什么产品，模拟销售人员帮助客户完成购买过程” [6]，现在这个定义已被广泛引用。

目前，个性化推荐系统已广泛运用到各行业中，推荐对象包括书籍、音像、网页、文章、新闻等，如表 2-1 所示。

表 2-1 推荐系统一览表

领域	推荐系统
电子商务	Amazon.com,Dietorecs,Ebay,entree,FAIRWIS,Ghani,Levis,LIBRA,MIAU,RIND,Ski-europe.com
网页	Commty,search,ass'nt,Fab,Foxtrot,ifWeb,MEMOIR,METIOREW,ProfBuilder, QuIC, Quickstep,R2P,Siteseer,SOAP,SurfLen
音乐	CDNOW,CoCoA,Ringo
电影	CBCF, Nakif, Moviefinder.com,MovieLens,Recommends' Explorer,Reel.com,Virtual rev's(Tatemura)
新闻过滤	GroupLens,PHOAKS,P-Tango
电子邮件过滤	Tapestry
专门查找器	Expertise Recommender,Referral Web
其它	Campiello,ELFI,OWL

根据推荐对象的特点，目前主要有两种类型的个性化推荐系统，一种是以网页为对象的个性化推荐系统，主要采用 Web 数据挖掘的方法与技术，为用户推

荐符合其兴趣爱好的网页：另一种是网上购物环境下的、以商品为推荐对象的个性化推荐系统，为用户推荐符合其兴趣爱好的各类产品，如各种书籍、音像等，这种推荐系统是一般意义上的电子商务个性化推荐系统，简称电子商务推荐系统。目前国内外对前者的研究和应用较多，后者则很少，尤其是没有把个性化推荐与企业营销决策、客户关系管理等结合起来研究。本文协作过滤算法的研究背景则是后者。

2.1.2 个性化推荐系统的研究内容

个性化推荐的研究有四方面的问题：首先，要解决推荐系统的信息来源问题——推荐系统的基础是用户兴趣资料信息，如何在电子商务环境下尽可能获得更多的用户相关信息，并以合适的形式表示，是进行个性化推荐的前提；其次，要实现被顾客接受和认可的个性化推荐，设计准确、高效率的个性化推荐算法是个性化推荐的核心问题；另外，要让推荐系统为广大用户所接受，必须对推荐系统作出客观、综合的评价，尤其要注意从准确性、个性化、安全性、用户满意度等多方面进行评价；推荐系统的应用是最终研究的落脚点，推荐系统不仅能为用户提供完全个性化购物环境，更应为企业的销售决策和客户关系管理提供支持。

在电子商务环境下，用户信息的收集表示是电子商务个性化推荐的基础。根据当前对电子商务环境下对用户信息收集表示的研究来看，主要着眼于研究如何有效的收集能反映用户兴趣偏好的信息，以及如何通过网络数据挖掘等方法更自动化地收集用户的隐式信息，解决用户信息收集过多的依赖于显式评价数据的问题。

个性化推荐技术是个性化推荐系统的核心问题。目前的推荐技术有协作过滤推荐、基于用户统计信息的推荐、基于内容的推荐、基于效用的推荐、基于知识的推荐、基于规则的推荐，等等。协作过滤推荐是个性化推荐中研究和应用最多的方法，被广泛的应用于电子商务网站、数字图书馆、网页搜索、新闻过滤等，其著名的推荐系统有 Tapestry[1]、GroupLens/NetPerceptions[2,3]、Ringo/Firefly[4]等，其前提假设是存在具有相似兴趣爱好的用户群，每个用户都有与其兴趣爱好相似的邻居用户。预测用户对某一项目的偏好是根据邻居用户对该项目的偏好程度计算的，也就是说如果其邻居用户喜爱某项目，则该用户也很可能会喜爱该项目。协作过滤最大的优点是不需要分析对象的特征属性，所以对推荐对象没有特殊的要求，能处理非结构化的复杂对象，如音乐、电影等。

对推荐系统总体性能的评价是个性化推荐系统研究的重要组成部分。目前大都只是采用准确率、召回率等评判尺度对推荐算法进行评价[9]，并没有真正意义上的、提升到对整个推荐系统进行的评价，尤其缺乏从个性化程度、持久性程

度、系统的安全性以及用户接受程度等多方面对推荐系统进行综合的评价。

在应用研究方面,由于目前从事电子商务个性化推荐系统研究的人员主要是来自计算机科学领域的专家学者,研究主要集中于个性化推荐技术,还很少有管理学界的专家学者,从更广阔的范围和更深入的专门领域,比如从营销决策、市场分析、客户管理以及系统集成的角度去研究电子商务个性化推荐的应用。虽然文献[22]给出了五种推荐系统的应用模型,分别阐述了应用目标及相应的对策,但只是单个孤立的推荐系统应用模式,并没有从系统集成和商业智能的角度去讨论其应用。

2.1.3 个性化推荐系统的经济效益

个性化推荐系统的最大优点在于它能收集用户兴趣资料并根据用户兴趣偏好主动的为其作出个性化的推荐。也就是说,当用户每次输入用户名和密码登录电子商务网站后,推荐系统就会按照当前用户偏好程度的高低推荐其最喜爱的N个产品,而且系统给出的推荐是实时更新的,即当系统中的产品库和用户兴趣资料发生改变时,给出的推荐序列会自动改变,这就大大方便了用户,也提高了企业的服务水平。

总体说来,个性化推荐系统的作用主要表现在以下几个方面:一方面,使用户从无限的网络资源和商品世界中解脱出来,大大节约了用户采购商品的时间和成本;与此同时,推荐系统的个性化推荐服务,提高了客户对电子商务网站的忠诚度(Building Loyalty),将更多的电子商务网站浏览者转变为商品的购买者,从而提高电子商务网站的交叉销售能力(Cross-Selling),为电子商务企业赢得了更多的发展机会。

研究表明,在基于电子商务的销售行业使用个性化推荐系统后,能提高销售额2%--8%[21],尤其在书籍、电影、CD音像、日用百货等产品相对较为低廉并且商品种类繁多的行业,以及用户使用个性化推荐系统的程度较高的行业,推荐系统能够大大提高企业的销售额。

个性化推荐系统和销售系统(Marketing Systems)、供应链决策支持系统(Supply-Chain Decision-Support systems)既相似又有不同。销售系统是帮助销售人员如何把产品销售出去。推荐系统的最终目的是帮助用户,辅助用户购买什么产品做出决策。

供应链决策支持系统是帮助生产者决定什么时候生产多少什么产品,以及仓库应该存储多少各类产品,其最终目的是为企业生产者服务的,而同样的,推荐系统也是面向用户的系统。

电子商务个性化推荐有显著的经济效益,可以大大降低企业的 TOC(Total

Ownership Cost)。可以预见,在未来的几年内,我国电子商务个性化推荐将有相当广阔的发展前景。

2.1.4 个性化推荐系统的类别

个性化推荐系统以用户为中心,为用户提供服务,可以根据用户获得推荐系统推荐的自动化程度和持久性程度对电子商务推荐系统进行分类:

- 1)自动化程度: 用户为了得到推荐系统的推荐是否需要显式的输入信息, 自动化程度分为自动化方式和手工方式。
- 2)持久性程度: 电子商务推荐系统产生推荐是基于用户当前的单个会话还是基于用户的多个会话。

根据用户获得推荐的自动化程度和持久性程度,可以将电子商务个性化推荐系统分为基于属性的电子商务推荐系统、商品相关性推荐系统和用户相关性推荐系统。

- 1)基于属性的电子商务推荐系统: 根据商品的属性特征向用户产生推荐列表, 这种推荐系统类似于搜索引擎, 用户需要手工输入所需商品的属性特征。基于属性的电子商务推荐系统需要用户显式输入商品的属性特征, 因此属于手工方式推荐。产生的推荐可以基于用户的单个会话, 也可以基于用户的多个会话。典型例子包括 Amazon 提供的 Delivers 推荐, Reel 提供的 Movie Map 推荐。
- 2)商品相关性推荐系统: 根据商品之间的相关性向用户产生相应的推荐的推荐系统。商品相关性推荐系统可以是全自动化推荐系统, 也可以是全手工方式推荐系统。这种推荐技术一般是基于用户的单个会话。典型例子如 Amazon 提供的 Customers who bought this book also bought 推荐, CDNOW 提供的 Album Advisor 推荐。
- 3)用户相关性推荐系统: 又称为协作过滤推荐系统, 这种推荐系统首先搜索当前用户的最近邻居, 然后根据最近邻居的购买历史或评分信息向当前用户产生推荐。用户相关推荐一般不需要用户显式输入信息。产生的推荐一般是基于用户的多个会话。典型例子包括 Amazon 提供的 Book Matcher 推荐, Movie Finder 提供的 We Predict 推荐。

2.2 个性化推荐系统的结构

整个个性化推荐系统主要可以分为三个模块: 用户输入功能(Input functional)模块、推荐方法(Recommendation method)模块、输出功能(Output functional)模块。输入可以来自客户个人和社团群体两部分。客户个人输入(Targeted Customer Inputs)主要指目标用户对项目的评价, 即要求获得推荐的人为得到推荐而必须对

一些项目进行的评价，以表达自己的偏好，包括隐式浏览输入、显式浏览输入、关键词和项目属性输入和用户购买历史等。社团群体输入(Community Inputs)主要指集体形式的评价数据，包括项目属性、社团购买历史、文本评价、等级评分。

推荐系统的输出是推荐系统在获得输入信息后，推荐所给用户的内容，主要形式有：

一、建议(Suggestion)，又分为单个建议(Single Item)、未排序建议列表(Unordered List)、排序建议列表(Ordered List)，典型的如 TOP-N-推荐系统根据客户的喜好向客户推荐最可能吸引客户的 N 件产品；

二、预测(Prediction)：系统对给定项目的总体评分；

三、个体评分(Individual Rating)：其他客户对商品的个体评分；

四、评论(Review)：其他客户对商品的文本评价。

推荐方法模块是推荐系统的核心部分，决定着推荐系统的性能优劣。推荐方法模块以个性化推荐技术和算法为技术支撑，具体的在本章第三节中详细介绍。

2.2.1 推荐系统的图形化用户界面

电子商务推荐系统向客户进行推荐的方式有许多种，它可以是建议或者通过计算得到的预测，也可以是其他客户对产品的个人评价 (Individual Rating)，评论(Review)等，而选择哪一种方式主要取决于该电子商务网站希望客户如何使用推荐。

按照推荐系统的界面表现形式主要分为以下几种：

(1)浏览(Browsing)：客户提出对特定商品的查询要求，推荐系统根据查询要求返回高质量的推荐。

(2)相似项(Similar Item)：推荐系统根据客户购物篮中的商品或客户感兴趣的物品推荐类似的物品，为客户提供个性化的推荐。

(3)电子邮件(Email)：推荐系统通过电子邮件的方式通知客户可能感兴趣的物品信息，使网站与客户保持联系，提高客户对网站的信任度，从而增加对该网站的访问量。

(4)评论信息(Text Comments)：推荐系统向客户提供其他客户对相应产品的评论信息，客户根据他人对产品好坏的评价，来做出自己的判断。

(5)等级评价(Average Rating)：推荐系统向客户提供其他客户对相应产品的等级评价，而不是产品的评论信息，通过对等级评价的相应统计和分析，较直观地表示出其他客户对产品的观点或看法，使客户易于接受该种推荐。

(6) Top-N：推荐系统根据客户的喜好向客户推荐最可能吸引他的 N 件产品，一方面可以把网站的浏览者转变为客户，另一方面帮助客户决定是否购买自己最

初感到犹豫不决的产品。

(7)搜索结果排列(Ordered Search Results): 推荐系统列出所有的搜索结果,并将搜索结果按照客户的兴趣度降序排列。

2.2.2 个性化推荐系统的输入

不同类型的电子商务推荐系统,其输入信息也不相同。不同电子商务推荐系统根据不同的输入信息产生不同类型的推荐。电子商务推荐系统的输入可以是用户当前的行为,也可以是用户访问过程中的历史行为。在大型的电子商务系统中,为了产生高质量的推荐,推荐系统可能需要多种类型的输入信息。

推荐系统的输入包括多种形式,主要包括:

1)隐式浏览输入:将用户访问电子商务 Web 站点的浏览行为作为推荐系统的输入,用户的浏览行为与访问一般的 Web 站点没有区别。并不知道电子商务推荐系统的存在。用户当前正在浏览的商品、用户购物篮中选择的商品、用户的浏览路径等都可以作为隐式浏览输入信息。

2)显式浏览输入:也是将用户的浏览行为作为电子商务推荐系统的输入,但与隐式浏览输入不同,用户的显式浏览输入是有目的的向电子商务推荐系统提供自己的兴趣爱好。例如,电子商务系统提供一系列热门商品供用户选择,用户只选择浏览自己感兴趣的商品列表,电子商务根据用户的浏览行为向用户提供个性化的推荐服务。

3)关键字/商品属性输入:用户在搜索引擎中输入关键字作为推荐系统的输入,或者将用户当前正在浏览的商品类别作为推荐系统的输入。这种类型的输入不同于用户随意的浏览行为,用户输入的目的就是在电子商务系统中搜索自己需要的商品。

4)用户评分输入:将用户对商品的数值评分数据作为推荐系统的输入。电子商务推荐系统列出一系列商品让用户评分,用户的评分可以是一个数值,数值大小表示用户对商品的喜好程度,也可以是一个布尔值,0 代表不喜欢,1 代表喜欢。用户提供的评分数据使得电子商务推荐系统可以为用户提供个性化的推荐服务。

5)用户文本评价输入:用户对已经购买的商品或自己熟悉的商品以文本的形式进行个人评价,推荐系统本身并不能判断这些评价的好坏。其他用户浏览该商品时,可以看到用户对商品的文本评价信息。

6)编辑推荐输入:将领域专家对特定商品的评价作为推荐系统的输入,领域专家对商品的性能特点进行全面详细的介绍,用户通过专家的专业介绍,可以对自己并不熟悉的商品加深认识,从而决定是否购买该商品。

7)用户购买历史输入: 推荐系统将用户的购买历史作为隐式评分数据。一旦用户购买了特定商品, 则认为用户喜欢该商品。推荐系统根据用户的购买历史产生相应的推荐。但是用户购买了某件商品并不代表用户喜欢该商品, 所以在精确的推荐系统中, 用户可以对购买的商品进行重新评分, 从而使推荐系统产生更精确的推荐。

2.2.3 个性化推荐系统的推荐形式

一般的, 个性化推荐的形式有: 推荐产品、提供个性化的产品信息和社会团体评价。通过这些形式, 个性化推荐系统在三方面使电子商务得益:

- 一、帮助用户找出自己想要购买的产品;
- 二、促使浏览者成为购买者;
- 三、通过向用户推荐购买额外的产品, 提高交叉销售。

不同类型的推荐系统, 其推荐结果的输出形式也各不相同, 大型电子商务系统可以同时向用户产生多种不同形式的输出。

推荐系统的输出形式主要包括:

1)相关商品输出: 推荐系统根据用户表现出来的行为特征或电子商务系统的销售情况向用户产生商品推荐, 这种方式是电子商务推荐系统中最为普遍的一种输出。相关商品输出可以基于简单的销售排行向用户推荐热门商品: 也可以基于对用户的行为特征进行深入分析, 发现用户的购买行为模式, 从而产生个性化的推荐。

2)个体文本评价输出: 电子商务推荐系统向目标用户提供其他用户对商品的文本评价信息个体文本评价一般是非个性化的, 对每个商品而言, 所有用户得到的个体文本评价均相同。

3)个体评分输出: 向目标用户提供其他用户对商品的数值评分信息。个体评分输出没有大量的文本描述信息, 因此更加简洁明了。个体评分输出比较适合于个体数值评分数据比较少的场合。

4)平均数值评分输出: 电子商务推荐系统向用户提供其他用户对商品数值评分信息的平均值。这种输出形式具有简洁明了的优点, 用户可以立即获得对该商品的总体评价。

5)电子邮件输出: 电子商务推荐系统通过电子邮件的形式向用户提供商品的最新信息。这种输出形式可以吸引用户再次访问电子商务系统, 从而达到保留用户, 防止用户流失的目的。

6)编辑推荐输出: 向用户提供领域专家对商品的专业介绍, 用户通过专家的专业介绍可以对自己并不熟悉的商品加深认识, 了解商品的性能特点, 从而决定

是否购买该商品。

2.3 主要的个性化推荐技术

个性化推荐技术是个性化推荐系统中最核心、最关键的技术，在很大程度上决定了个性化推荐系统性能的优劣。

目前主要的个性化推荐技术有协作过滤推荐、基于内容的推荐、基于人口统计信息的推荐、基于效用的推荐、基于知识的推荐、基于规则的推荐等。具体的推荐技术如下页表 2-2 所示。

目前使用比较广泛的个性化推荐技术主要是基于内容的推荐(Content-based recommendation)和协作过滤推荐算法（Collaborative Filtering Recommendation）。基于内容的推荐技术需要利用信息抽取或机器学习的方法通过对项目的属性描述进行推荐[23]。一般的，基于内容的推荐通过分析用户访问过的项目的内容，来预测用户偏好并推荐其感兴趣的项目。相对而言，协作过滤推荐根据用户对这些项目的评价的集合来进行推荐。两种推荐技术都是利用现有的信息(用户/项目特征或用户评价)，推荐其感兴趣的项目。

表 2-2 各种个性化推荐技术

推荐技术	背景条件	输入	主要步骤
协作过滤的推荐	U 对 I 的评价	U 对 I 的评价等级	识别 u 的邻居用户；根据其生成 i 的评价分。
基于内容的推荐	I 的特征属性	U 对 I 的评价等级	根据 U 的评价生成项目的分类器
基于人口统计信息的推荐	U 的人口统计信息及对 I 的评价	关于 U 的人口统计信息	识别 u 的相似用户；根据其生成 i 的评价分
基于效用的推荐	I 的特征	描述 U 对 I 偏好的效用函数	把效用函数用于各项目；生成各项目的排序。
基于知识的推荐	I 的特征、I 怎么满足用户的知识	对 U 需要和兴趣的描述	计算各项目 i 和用户需要的匹配程度

注：U 表示所用用户的集合，I 表示所有项目的集合；u 表示当前要预测的用户；i 表示当前要预测的项目。

2.4 组合推荐技术

目前并没有一种非常完美的推荐方法。所以，要实现一个现实的推荐系统，需要结合各种基本的推荐技术。从理论上来说，组合能减少协作过滤和其它方法的各自的弱点。

一般而言，推荐的组合有以下几种思路[35]：

(1) 加权(Weight)：加权用多种推荐技术得到的对某一项目的得分，得到一总的得分，以此得出推荐结果。

(2) 切换(Switch)：具体采用哪种推荐技术取决于当时所处的具体情况，根据具体的场合和时机切换不同的推荐技术。

(3) 混合(Mixed)：同一时间采用多种推荐技术。

(4) 特征组合(Feature combination)：来自不同推荐数据源的特征组合被一种推荐算法所采用。

(5) 层叠(Cascade)：一个推荐器从另一种推荐器中提炼抽取一部分的推荐技术。

(6) 特征扩充(Feature augmentation)：一种技术的输出作为另一种推荐技术的特征输入。

(7) Meta-level：被一种推荐器学习的模型作为另一种推荐器的输入。

目前较充分研究过的推荐组合有：

(1) Content-based/collaborative feature augmentation hybrid：这种可能是应用研究最早的，如应用在基于内容的“filterbot”系统中；

(2) Collaborative/content-based meta-level hybrid：用协作过滤的信息去生成全面用户评价数据集，然后用这个数据集比较不同的项目；

(3) Collaborative/demographic augmentation hybrid：协作过滤技术分辨出它的邻居用户，用这个信息作为用户的一个基本人口统计信息。

从这些组合研究的研究状况可以看出，对协作过滤和基于内容的技术组合研究是比较多的。之所以如此，其中一个重要原因是评价数据很容易得到，比如可以使用著名的 EachMovie 数据库，该数据库提供了大约 250 个用户对电影作出的 45,000 个评价。其他的推荐组合研究的要少一些，尤其是基于用户人口统计信息的推荐，由于存在在线数据保密性问题，在 25 种可能的组合种，只有 4 种得到过研究。

此外，在采用组合推荐技术的时候，必须注意组合策略。这些策略和被组合的推荐技术有关。比如对于基于人口统计信息，基于内容的和协作过滤技术来说，必须考虑历史数据库的数量和质量；而对于基于知识的推荐来说，则必须考虑有哪些可用的知识库。

2.5 协作过滤算法

协作过滤推荐算法(collaborative filtering recommendation) 是目前研究最多的个性化推荐技术,它基于邻居用户的资料得到目标用户的推荐,其推荐的个性化程度高。其著名的系统有 GroupLens/Net Perceptions[4]、Ringo/ Firefly[5]及 Tapestry[6]等。协作过滤算法的最大优点是对推荐对象没有特殊要求,能处理非结构化的复杂对象,如音乐、电影。

下表 2-3 是各个学者对协作过滤算法定义的整理。

表 2-3 各个学者对协作过滤的定义

学者（年份）	定义说明
Resnick(1994) Hill(1995) Shardandand & Maes(1995) Konstan(1997)	协作过滤技术是利用用户群体的集体观点来推荐项目给个人用户[21]。
Dhillon(1995)	协作过滤主要是以属性或兴趣相近的用户经验与建议作为个性化咨询的基础。
Palme(1997)	协作过滤又称为“评比”或“群体过滤”(Social Filtering),是提供使用者高品质资源的一种机制[22]。
Sarwar(1998)	协作过滤技术通过整理社群内使用者的观点,并且针对每一个个别使用者进行个性化的推荐建议[24]。
Good(1999)	协作过滤着重在相同偏好用户对商品的定义以及如何利用他们的观点来进行推荐[24] 。
Badrul(2000)	1.协作过滤系统是由其他用户的观点推荐商品给目标用户。 2.协作过滤技术是在推荐过程中,比对用户的评价与其他顾客的差别来动作[26]。
Schafer(2000)	协作过滤是一种“用户与用户之间相关程度”的推荐机制,它是以在一个电子商务网站上从事购买行为顾客间的相关性为基础[23]。
Heylighten(2001)	协作过滤技术是由计算用户与其它用户的喜好相似性来产生个性化建议[28]。

综上，本研究对协作过滤技术定义如下：

- 1.一种搜集和比对每个使用者对商品喜好评价的过程；
- 2.一种群体咨询过滤的形式，将用户的口碑行销自动化和正式化的过程；
- 3.它需要许多用户的知识去预测某个用户的喜好；
- 4.利用用户之间喜好的相关程度的统计方法去发现那些有相同喜好的使用者。

2.5.1 协作过滤算法的思路及过程

协作过滤推荐是目前应用广泛且效率较高的一种个性化推荐技术。本节介绍将传统的协作过滤推荐的算法思路及其过程。

由上一节定义可知，协作过滤推荐（Collaboration Recommendation）是基于邻居用户的兴趣爱好预测目标用户的兴趣偏好，算法首先使用统计技术寻找与目标用户具有相同喜好的邻居，然后根据目标用户的邻居的偏好产生向目标用户的推荐。




图 2-1 协作过滤的算法流程图

协作过滤是基于这样的假设：为用户找到真正感兴趣商品的方法是找到与用户有共同兴趣爱好的相似用户，并将相似用户感兴趣的商品推荐给该用户。协作过滤系统的基础是：(1)用户是可以按兴趣分类的；(2)用户对不同商品评价包含

了用户的兴趣信息；(3)用户对未知商品的评价将和相似用户的评价相似。可见，协作过滤算法是利用用户数据作为推荐的基础。

协作过滤推荐算法的出发点是：兴趣相近的用户可能会对同样的东西感兴趣。所以，只要维护关于用户喜好的数据，从中分析得出具有相似品味的用户，然后就可以根据相似用户的意见来向其进行推荐。

另一种可能的出发点是：用户可能偏爱与其已购买的东西相类似的商品。可以根据用户对各种东西的评价来判断商品之间的相似程度，然后推荐与用户兴趣度最接近的那些商品。

前一种思路以用户之间的关系为中心，而后一种思路则以项目与项目之间的关系为着眼点。

协作过滤的算法流程图如上图2-1，协作过滤算法主要有四个步骤：

1. 表示(Representation)：在一个采用协作过滤技术的推荐系统中，用户输入评分数据可以用一个 $m \times n$ 阶用户—项目评分矩阵R(如表2-4所示)，m行代表m个用户，n列代表n个项目，第i行第j列的元素 r_{ij} 代表用户i对项目j的评分。评分可以用2进制的0和1来表示的用户偏好(喜欢/不喜欢)或购买状态(已购买/未购买)，也可以用分级表示的用户对项目的喜好值表示(例如：MovieLens中用户对电影的评分为从0到5之间的整数来代表用户的喜好，0表示没有评分，1到5表示用户喜欢程度)。

表2-4 用户—项目评分矩阵R

Item \ User	I_1	I_2	...	I_j	...	I_n
U_1	$R_{1,1}$	$R_{1,2}$	...	$R_{1,j}$	...	$R_{1,n}$
U_2	$R_{2,1}$	$R_{2,2}$	...	$R_{2,j}$	...	$R_{2,n}$
...	...	...	...	...	...	...
U_i	$R_{i,1}$	$R_{i,2}$	...	$R_{i,j}$	...	$R_{i,n}$
...	...	...	...	...	...	...
U_m	$R_{m,1}$	$R_{m,2}$	...	$R_{m,j}$	...	$R_{m,n}$

2.选取用户间或项目间的相似度的度量公式

目前有如下几种度量公式可供选择：

- (1)余弦相似性度量公式(Cosine-based Similarity):如公式(3-1),(3-5)所示。
- (2)修正的余弦相似性度量公式(Adjusted Cosine Similarity): 即Spear相关系

数度量，如公式(3-2),(3-7)所示。

(3)相关相似度度量公式(Correlation-based Similarity): 即Pearson相关系数度量，如公式(3-3),(3-6)所示。

3.邻居的形成

一般地说，邻居用户的确定有两种方法，一是根据预先确定的相似度阈值，选择相似度大于阈值的作为邻居用户；二是根据预先确定的邻居数N，选择相似度最大的前N个用户作为邻居用户。

4.预测评价

预测方法主要如下几种统计的方法：

(1)简单平均值(Simple Average)

最简单的就是平均所有邻居用户的对预测项目的评分值。

(2)加权平均值(Weightd Average)

考虑到当前用户及其邻居用户之间相似性，对于与当前用户更为相似的用户在预测中给赋予更多的作用，否则给予较少的权重，其计算公式如统计公式(3-8)，(3-11)，(3-12)所示。

(3)中心加权平均值(Deviation-from-Mean)

考虑到不同用户的评价值，加权评价与该用户平均评价分的差值，而得到的如统计公式(3-4), (3-15)所示的统计计算方法。

2. 5. 2 协作过滤算法的分类

近年来陆续提出了许多协作过滤的实现算法，大致可以分为两类：基于内存的协作过滤算法和基于模型的协作过滤算法。其具体的分类如下图 2-2 所示。




图 2-2 协作推荐算法的分类

1. 基于内存的协作过滤算法

先用统计的方法得到具有相似兴趣爱好的邻居用户,再基于邻居进行计算,基于内存的协作过滤算法使用整个用户-项目数据库进行预测,它又分为 User-based 协作过滤算法和 Item-based 协作过滤算法,这两个算法将在第三章 3.1 中予以详细地介绍。

2. 基于模型的协作过滤算法

基于模型的协作过滤算法,先用历史数据得到一个模型,再用一个模型进行预测[40],所广泛采用的技术包括聚类技术、贝叶斯网络、机器学习方法、关联规则、神经网络、潜在语义索引(Latent semantic indexing)等。

(1) 聚类技术[28,29]

最近邻居算法是基于对各个单个用户进行的预测,聚类技术则是基于对一组用户进行的预测。聚类技术(clustering)通过观察与分析,可以将数据集划分为多个类或簇(cluster),使得同一簇中的对象具有较高的相似度,而不同簇中的对象相似度差别很大。运用到个性化推荐系统中,首先根据各个用户的喜好记录进行聚类,每类用户具有相近的兴趣习惯。一旦聚类完成,就可以依据所属类的所有成员的共同喜好向用户进行推荐。

实验表明,使用聚类技术的预测准确率不如最近邻居方法,因为基于类进行推荐具有较低的个性化程度,尤其是对于处于类的边缘地带的用户,其喜好可能与类成员的共同喜好有较大的偏差。但是,将用户事先分类可以大大减少所需的计算量,不失为正确率和效率之间一种较好的折中方法。

另外,聚类也可以用作最近邻居算法的预处理步骤,这样既可缩小下一步的计算范围,也有利于将计算任务分布处理。

(2) 贝叶斯网络[26,29]

由 Breese, Heckman 和 Kadie 提出的贝叶斯网络建立的是一个概率模型。在训练得到的网络结构中,每个节点都有一组对其有影响的父结点,一旦父节点的值已知,就可以预测该节点的值。节点对应的条件概论表用决策树的形式表示,从中给出当父节点取各种可能值进子节点取值的条件概率。

贝叶斯网络建立的模型相当小巧快捷,推荐的精确度不亚于最近邻居算法。不过,由于模型建立的时间复杂性较高,比较适合于变化较少的环境。

(3) 机器学习方法[24,25]

分类(Classification)是一种重要的机器学习方法,也叫基于示例的学习。在给定的训练集中,每个训练样本都已预先标明属于哪个类,学习过程试图从训练集中提取分类模型,用分类规则、判定树或数学公式的形式描述出每个类的特征。

该分类模型可以用来对以后新的数据进行分类。类似地，预测用于预测连续的值。

协作过滤的过程也可以看作是一个分类或预测任务。以表 2-5 为例，假定我们要预测用户 4 对项目 5 的态度，把用户 4 已经打分的项目 I_1, I_2, I_3 作为训练集的标本，其他用户对项目的评分构成描述项目的特征向量，用户 4 对这些项目的评分作为类标签，任务可以描述为：为用户 4 构筑一个函数，自变量是其他用户对某个项目的看法，函数值为用户 4 对该项目的喜好程度。这里用户对项目的评分可以采用表格中的连续值，也可以将其简化为喜欢或不喜欢的离散值。

表 2-5 评价矩阵

	I_1	I_2	I_3	I_4	I_5
U_1	4		3		
U_2		1		2	
U_3	3	4	2		4
U_4	4	2	1		?

有许多实现分类的方法可供选择，包括规则归纳、判定树、神经网络、贝叶斯等，预测方法则多用回归模型。

(4)关联规则[27,29]

数据挖掘技术是近年来兴起的一门数据分析技术，前面所提到的聚类技术、分类和预测技术起源于人工智能领域，但也是数据挖掘中非常重要的研究课题。与机器学习的不同之处是数据挖掘更关注于大规则数据集中的运用，所以更适合于电子商务环境中的推荐系统。将数据挖掘技术运用到推荐系统中将是一种必然趋势。

目前在推荐系统中最常用的数据挖掘技术是关联规则。关联规则挖掘最早起源于购物篮分析，即通过研究顾客放入商品购物篮中的不同商品分析顾客的购买习惯，了解哪些商品经常被顾客同时购买，发现的这种关系可以帮助零售制定营销策略，例如货架摆设、促销或捆绑销售等。反映商品同时购买的模式采用关联规则的形式。例如 $P = \{P_1, P_2, \dots, P_m\}$ 是 m 个商品的集合，每个事务 $T \subseteq P$ 是一起购买的商品的集合。关联规则是形如 $X \Rightarrow Y$ 的蕴涵式，其中 $X, Y \subseteq P$ 且 $X \cap Y = \emptyset$ ，含义为如果事务 T 中包含集合 X 中的商品，则很有可能集合 Y 中的商品也会被一同购买。

关联规则是否真正有用，通过支持度和置信度来衡量。关联度 S 是事务中包含 $X \cup Y$ 的比例，而置信度 c 是数据库中包含 X 的事务同时也包含 Y 的百分比。通常由使用者设定最小支持阈值，同时也满足两者的关联规则则被认为是有意

义的。为某个用户推荐 N 种商品可以通过关联规则来实现。首先为每个用户产生一

条记录，包括该用户所有曾经购买过的商品，运用关联规则的挖掘算法从这个数据找到所有满足最小支持度阈值和最小置信度阈值的关联规则。然后从这些规则中找出被目标用户支持的那些(即用户购买了所有出现在规则左边的商品)，设 P_u 是出现在这些规则右边但目标用户尚未购买的产品集合，根据规则的置信度对产品，向用户推荐前 N 种。如果某个商品同时被多条规则推荐，则取具有最高置信度的规则。较著名的关联规则挖掘算法有 Apriori, DHP(基于散列)和 FP-树(频繁模式树)等。

2.6 小结

对个性化推荐系统的全面了解是对推荐算法和系统结构等方面进行分析和研究的基础。

本章介绍了个性化推荐系统的概念、类型、推荐形式、组成和作用，个性化推荐系统的研究内容和主要的个性化推荐技术协作过滤推荐算法的主要思想及其所采用的各种技术。

第三章 基于降维与项目评估预测的协作过滤算法

协作过滤推荐是目前应用广泛且效率较高的一种个性化推荐技术。

在个性化推荐的各种方法中，传统的协作过滤推荐的准确性较高，但存在冷开始和稀疏性问题，而基于降维与项目评估预测的推荐能够有效的克服这些问题并提高推荐质量。本章是本文的核心章节，论述采用基于降维与项目评估预测的推荐改进协作过滤的理论依据和具体算法。首先分析协作过滤推荐的优劣，然后说明如何利用基于降维和项目评估的协作过滤算法能较好地解决传统的协作过滤推荐中冷开始和稀疏性的问题，最后指出优化推荐算法的详细步骤和说明。

3.1 协作过滤推荐算法

3.1.1 User-based 协作过滤算法

User-based协作过滤推荐算法是目前应用广泛且效率较高的一种个性化推荐算法。该算法是协作过滤方法中最早提出的一种算法，所以一般情况下如果单独提起协作过滤推荐，指的就是基于User-based协作过滤。

User-based协作过滤算法描述：算法采用一个 $m \times n$ 阶用户—项目评分矩阵 R 来表示用户输入的评分数据，使用统计技术寻找与目标用户有相同喜好的邻居，然后根据目标用户的邻居的喜好产生向目标用户的推荐。User-based协作过滤算法主要有三个步骤：

- 1)用户之间相似度的度量方法主要有如下三种：
- 余弦相似度 (Cosine-based Similarity)：即余弦相关系数度量，用户评分可看作 n 维项目空间上的向量，用户 i 和用户 j 之间的相似度通过向量间的余弦夹角度量，余弦值越大表明两用户的相似程度越高。设用户 i 和用户 j 在 n 维项目空间上的评分分别表示为向量 $\vec{i}, \vec{j}$ ，则用户 i 和用户 j 的相似度 $\text{sim}(i,j)$ 为如下(3-1)公式所示：

$$\text{sim}(i,j)=\cos(\vec{i},\vec{j})=\frac{\vec{i}\cdot\vec{j}}{\|\vec{i}\|\cdot\|\vec{j}\|}$$

(3-1)

分子为两个用户评分向量的内积，分母为两个用户向量模的乘积。

- 修正的余弦相似度 (Adjusted Cosine Similarity)：即Spear相关系数度量，余弦相似度度量方法中并未考虑不同用户的评分尺度问题，为了改善上述缺陷，修正的余弦相似度度量方法减去用户对项目的平均评分，设用户 i 和用户 j 共同评分过的项目集合用 $I_{i,j}$ 表示， I_i 和 I_j 分别表示用户 i 和用户 j 评分过

的项目集合， $R_{i,c}$ 表示用户 i 对项目 c 的评分， $\overline{R_i}$ 和 $\overline{R_j}$ 分别表示用户 i 和用户 j 的平均评分。则用户 i 和用户 j 相似度 $\text{sim}(i,j)$ 为如下 (3-2) 公式所示：

$$\text{sim}(i,j) = \frac{\sum_{c \in I_{i,j}} (R_{i,c} - \overline{R_i})(R_{j,c} - \overline{R_j})}{\sqrt{\sum_{c \in I_i} (R_{i,c} - \overline{R_i})^2} \sqrt{\sum_{c \in I_j} (R_{j,c} - \overline{R_j})^2}} \tag{3-2}$$

最近邻居查询的目标就是对每一个用户 a ，在整个用户空间中查找用户集合 $N=\{N_1, N_2, \dots, N_s\}$ ，使得 N_1 与 a 的相似度 $\text{sim}(a, N_1)$ 最高， N_2 与 a 的相似度 $\text{sim}(a, N_2)$ 次之，依此类推。

- 相关相似度 (Correlation-based Similarity)：即Pearson相关系数度量，设用户 i 和用户 j 共同评分过的项目集合用 $I_{i,j} = I_i \cap I_j$ 表示，则用户 i 和用户 j 的相似度 $\text{sim}(i,j)$ 为如下 (3-3) 公式所示：

$$\text{sim}(i,j) = \frac{\sum_{c \in I_{i,j}} (R_{i,c} - \overline{R_i})(R_{j,c} - \overline{R_j})}{\sqrt{\sum_{c \in I_{i,j}} (R_{i,c} - \overline{R_i})^2} \sqrt{\sum_{c \in I_{i,j}} (R_{j,c} - \overline{R_j})^2}} \tag{3-3}$$

$R_{i,c}$ 表示用户 i 对项目 c 的评分， $\overline{R_i}$ 和 $\overline{R_j}$ 分别表示用户 i 和用户 j 对项目的平均评分。

2) 邻居的形成 (Neighborhood Formation)：该算法的核心部分是为一个需要推荐服务的目标用户寻找最相似的最近邻居集 (Nearest-neighbor)，即：对于一个用户 a 要产生一个根据相似度大小排列的邻居集合 $N=\{N_1, N_2, \dots, N_s\}$ 。 a 不属于 N ，以 N_1 到 N_s 相似度从大到小排列。最近邻居查找的效果和效率很大程度上决定了




图 3-1 邻居的形成

User-based协作过滤推荐算法的效果和效率。

图3-1示意了基于用户的协作过滤中邻居的一种形成过程:通过计算目标用户0和其他用户之间的相似性(比如计算欧几里得距离)，以点0为中心的1-6个最近用户被选择为邻居。用户之间的相似性的计算可采用Pearson相关度方法和目

前常用的向量空间相似度计算方法等。

3) 推荐产生(Recommendation Generation): 从目标用户的最近邻居中产生 N 项产品推荐。设目标用户 a 的最近邻居集合用 SU_a 表示, 则用户 a 对项目 j 的预测评分 $P_{a,j}$ 可以通过用户 a 对最近邻居集 SU_a 中项目的评分得到, 这一步采用了中心加权的计算, 其计算方法为如下 (3-4) 公式所示:

$$P_{a,j} = \overline{R_a} + \frac{\sum_{n \in SU_a} \text{sim}(a,n) \times (R_{n,j} - \overline{R_n})}{\sum_{n \in SU_a} (|\text{sim}(a,n)|)}$$

(3-4)

$\text{sim}(a,n)$ 表示用户 a 与用户 n 之间的相似度, $R_{n,j}$ 表示用户 n 对项目 j 的评分。 $\overline{R_a}$ 和 $\overline{R_n}$ 分别表示用户 a 和用户 n 对项目的平均评分。

通过上述方法预测用户对所有未评分项目的评分, 然后选择预测评分最高的前若干项(Top-N)作为推荐结果给当前用户。

3. 1. 2 Item-based 协作过滤算法

Sarwar 教授于 2001 年最早提出 Item-Based 协作过滤推荐算法[26], 为了解决 User-Based 协作过滤算法的数据稀疏性问题。算法的基本思想是: 根据目标用已经评价过的项目与目标项目 i 的相似度, 选择 k 个最相似的项目 $\{i_1, i_2, \dots, i_k\}$, 同时得到对应的相似度 $\{s_{i_1}, s_{i_2}, \dots, s_{i_k}\}$, 然后将目标用户对这 k 个最相似的项目的评分及这 k 个最相似的项目与目标项目的相似度加权平均值为对目标项目的评分[37]。




图 3-2 计算相似度

Item-based 协作过滤算法主要分两个步骤:

1)项目相似度计算

Item-based 协作过滤推荐算法的关键步骤是计算项目间的相似度并选择最相似项目, 见上图 3-2 所示。计算项目 i, j 的相似度的基本思路是首先分离出共同评过分的项目的用户, 并且应用一种相似度计算技术去决定相似度 s_{ij} 。

- 余弦相似度(Cosine-based Similarity): 即余弦相关系数度量, 在此, 两个项目作为 m 维用户空间上的两个向量, 项目间的相似度通过计

算两个向量间的余弦夹角。如果用户对项目没有进行评分，则将用户对该项的评分设为 0。则项目 i 和项目 j 之间的相似度 $\text{sim}(i,j)$ 表示为如下 (3-5) 公式所示：

$$\text{sim}(i,j)=\cos(\bar{i},\bar{j})=\frac{\bar{i}*\bar{j}}{\|\bar{i}\|*\|\bar{j}\|} \tag{3-5}$$

分子为两个项目评分向量的内积，分母为两个项目评分向量模的乘积。

- 修正的余弦相似度(Adjusted Cosine Similarity)：即 Spear 相关系数度量，使用余弦相似度度量方法计算项目之间相似度的缺陷是没有考虑不同用户的评分尺度问题，修正的余弦相似度度量方法通过减去用户对项目的平均评分弥补上述缺陷，设对项目 i 和项目 j 共同评分过的用户集合用 U 表示，则项目 i 和项目 j 之间的相似度 $\text{sim}(i,j)$ 为如下 (3-6) 公式所示：

$$\text{sim}(i,j)=\frac{\sum_{u\in I_{i,j}}(R_{u,c}-\overline{R_i})(R_{u,c}-\overline{R_j})}{\sqrt{\sum_{u\in I_{i,j}}(R_{u,c}-\overline{R_i})^2}\sqrt{\sum_{u\in I_{i,j}}(R_{u,c}-\overline{R_j})^2}} \tag{3-6}$$

其中 $R_{u,i}$ 表示用户 u 对项目 i 的评分， $\overline{R_i}$ 和 $\overline{R_j}$ 分别表示对项目 i,j 的平均评分。

- 相关相似度(Correlation-based Similarity)：即 Pearson 相关相似度度量，为了确保相关性计算的精度，我们必须首先分离出共同评分的项目，设对项目 i 和项目 j 共同评分过的用户集合用 U 表示，则项目 i 和项目 j 之间的相似度 $\text{sim}(i,j)$ 为如下 (3-7) 公式所示：

$$\text{sim}(i,j)=\frac{\sum_{u\in I_{i,j}}(R_{u,c}-\overline{R_i})(R_{u,c}-\overline{R_j})}{\sqrt{\sum_{u\in I_i}(R_{u,c}-\overline{R_i})^2}\sqrt{\sum_{u\in I_j}(R_{u,c}-\overline{R_j})^2}} \tag{3-7}$$

其中， $\overline{R_u}$ 表示用户 u 对项目的平均评分。

2)形成邻居项目的集合

该算法的核心部分是为一个需要推荐服务的目标项目寻找其最相似的最近邻居集(Nearest-neighbor)，即：对一个项目 item 要产生一个根据相似度大小排列的邻居集合 $N=\{N_1, N_2,...,N_s\}$ 。Item 不属于 N,以 N_1 到 N_s 相似度从大到小排列。其形成过程与邻居用户集合的形成过程类似。

3)产生推荐

协作过滤系统中，最重要的一步是根据预测产生输出界面，这一步

是采用加权求和 (Weighted Sum)的方法来计算用户 u 对项 i 的预测评分 $p_{u,j}$ 为如下 (3-8) 公式所示:

$$p_{u,j} = \frac{\sum_{\text{all similar item},N} (s_{i,N} \times R_{u,N})}{\sum_{\text{all similar item},N} (|s_{i,N}|)}$$

(3-8)

3. 1. 3 基于降维的协作过滤算法

尽管协作过滤技术在个性化推荐系统中获得了极大的成功,随着电子商务系统规模的扩大,用户数目和项数目指数级增长,导致用户评分数据的极端稀疏性。由于用户的最近邻居至少对两件商品进行了共同评分,因此在用户评分数据极端稀疏的情况下,无法搜索到某些用户其最近邻居,导致协作过滤推荐算法无法对这些用户产生任何推荐。其次,在大规模数据集上搜索当前用户的最近邻居非常费时,难以保证协作过滤推荐算法的实时性要求。最后,协作过滤推荐算法也无法发现商品之间存在的隐含关联。

奇异值分解 (SVD, Singular Value Decomposition) 技术作为 LSI(Latent Semantic Indexing)技术的一部分,首先在信息检索领域得到了广泛的应用。

当时它的作用主要是用于解决信息检索中的同义词的问题,即用多种表达方法来说明一个已知的概念。之后类似的 SVD 方法用来解决这样的问题,即当一个词或文档添加到一个已知的矩阵后该矩阵的更新问题。这些方法后来被个性化推荐领域的研究者所采用。起先, Billsus and Pazzani 利用 SVD 方法的特性用来作为一种降维的手段。后来, GroupLens 至少在三个方面用到了 SVD 方法:

- 1.利用 SVD 方法降低用户-项目空间的维度,并在降维的空间作一些预测,但没有建立最近邻居;
- 2.在已经降维的空间产生用户最近邻,并应用到传统的基于用户的协作推荐算法中去;
- 3.利用 SVD 方法对用户-项目空间矩阵进行拆分以增强其扩展性。

由以上可知, SVD 方法是一种已经很成熟的矩阵降维技术,而且对于拆分稀疏矩阵有很好的效果。

奇异值分解是一种矩阵分解技术,它可将一个 $m \times n$ 阶的矩阵 R 分解为 3 个矩阵[38]:

$$R = T_0 \times S_0 \times D_0'$$

$$S_0 = \text{diag}(\sigma_1, \sigma_2, ..., \sigma_r)$$

(3-9)

其中, $\sigma_1 \geq ... \geq \sigma_r \geq 0$, T_0 和 D_0' 分别是 $m \times r$ 和 $n \times r$ 的正交矩阵($T_0 T_0' = I$), r 是矩阵 R 的秩($r \leq \min(m,n)$)。 S_0 是一个 $r \times r$ 的对角矩阵,所有的 σ_i 均大于 0 并按照大小顺序排列,称为奇异值(singular value)。通常对于矩阵 $R = T_0 S_0 D_0'$, T_0 、 S_0 、 D_0' 必须是满秩的,但奇异值分解有一个优点,它允许存在一个简化的近似矩阵,

对于 S_0 ，保留 k 个最大的奇异值，其余的用 0 来替代。

这样，我们就可以将 S_0 简化为仅有 k 个奇异值的矩阵($k < r$)。由于引入了 0，因此可以将 S_0 中值为 0 的行和列删除，得到一个新的对角矩阵 S ，如果矩阵 T_0, D_0 据此简化得到矩阵 $T、D$ ，那么有重构的矩阵 $R_k=TS D', R_k \approx R$ 。奇异值分解能够生成初始矩阵 R 的所有秩等于 k 的矩阵中与矩阵 R 最近似的一个。基于降维的协作过滤推荐算法将奇异值分解应用到协作过滤推荐算法中，用奇异值分解算法分解后的低维正交矩阵在原始矩阵的基础上降低了噪音，并且可以更有效的揭示用户和商品的潜在关联，而这种用户与商品的潜在关联的揭示正是奇异值分解所带来的好处。

基于降维的协作过滤推荐算法首先将用户评分数据矩阵 R 中评分值为 0 的稀疏项用相关列的平均值代替[36]。然后将矩阵每行规范化为相同长度，用 $r_{ij}-\bar{r}_i'$ 替原来的 r_i ($\bar{r}_i'$ 是相关列的平均评分值)。进行规范化的目的是因为选择商品数盘不同的用户对相似度计算结果的影响不同，容易造成偏差，规范化为相同长度后，选择商品数目较多的用户对相似度计算结果的影响降低了。经过这样的处理，可以得到矩阵 R' ，这是算法的输入矩阵。基于降维的协作过滤推荐算法如下所示 [36]:

基于降维的协作过滤推荐算法

输入：矩阵 R' 、用户 U 已评分过的项集合 I_u

输出：相关矩阵 $T、S、D$

过程：

Step 1 用奇异值分解方法分解矩阵 R' 得到矩阵 $T_0、S_0、D_0'$ ；

Step 2 将 S_0 简化为维数为 k 的矩阵，得到 $S(k < r, r$ 是矩阵 R 的秩)

Step 3 相应简化矩阵 $T_0、D_0$ 得到 T, D 。

Step 4 计算 S 的平方根得到 $S^{1/2}$

Step 5 计算两个相关矩阵 $TS^{1/2}, S^{1/2}D'$ 。

$TS^{1/2}$ 是 $m \times k$ 的矩阵，它描述的是用户在 k 维空间中的关系，可以理解为用户矩阵。矩阵 $S^{1/2}D'$ 大小为 $n \times k$ ，可以理解为相应的项矩阵。接下来用这两个简化矩阵来产生推荐结果。

1)最近邻居集合 top--N 推荐集的产生：采用向量空间方法计算相似度，这里分析的对是经过 SVD 分解后的 $m \times k$ 矩阵 $TS^{1/2}$ 。由于 $TS^{1/2}$ 描述的是用户在 k 维空间中的关系，因为经奇异值分解，大大降低了它的数据稀疏性，可以产生精确的最近邻居集合和相应的 top-N 推荐集。

2)用户兴趣度的计算:除了 top-N 推荐集外,还可以计算用户 u 对任意项 t 的兴趣度。因为两个矩阵 $TS^{1/2}$, $S^{1/2}D'$ 的乘积是规范化后的评估值,则对矩阵 $TS^{1/2}$ 的第 u 行和矩阵 $S^{1/2}D'$ 第 t 列的内积反规范化,就得到实际的预测值,如下 (3-10) 公式所示:

$$\text{pred}(u,t)=\bar{u} + TS^{1/2}(u) \times S^{1/2}D'(t) \quad (3-10)$$

$\bar{u}$ 是用户 u 对项的平均评分值。

基于降维的协作过滤推荐算法较好地解决了数据稀疏性的问题,同时,因为 $k \ll n$, 计算开销也有相应的降低,有利于解决推荐算法的伸缩能力问题。但其推荐的精确性会有一定下降。

3.2 优劣分析及其解决方法

协作过滤推荐的优势显而易见。它通过用户间的相互协助、根据用户对项目的评价的相似度分类,很容易得到比较精确的推荐结果,而且从邻居用户的反馈评价中得益,能够维持有效的推荐,容易挖掘出被推荐用户潜在的新兴趣。

协作过滤中使用的最广泛的算法是最近邻方法[39]。最近邻方法根据用户评分的相似度来得到目标用户的若干最近邻居,然后用最近邻居对项目评分的加权值来预测目标用户对项目的评分。然而,最近邻方法存在三个方面的缺点,即稀疏问题、冷开始问题(Cold-start)和特殊用户问题(Gray Sheep) [40],其中前两方面的问题也是本文所研究的重点。

3.2.1 稀疏问题 (Sparsity)

因为最近邻方法需要不同用户之间的相似程度,但对于两个用户之间没有都评过分的项,那么他们之间的相似度就无法求取,这就产生了稀疏性。

由于数据的极端稀疏性,在形成目标用户的最近邻居集合时,往往会造成信息的丢失,从而导致推荐效果的降低。例如,邻居用户关系传递性的丢失,用户 A 与用户 B 相关程度很高,用户 B 与用户 C 相关程度也很高,但由于用户 A 与用户 C 很少对共同的项目进行评价,而认为两者关联程序较低,由此而丢失了用户 A 与用户 C 之间潜在的关联。

目前解决这个问题的方法有如下几种:一是采用维度压缩的技术,降低矩阵的纬度[41],增加数据的密度,从而更容易发现用户间的相似度。二是采用基于内容的推荐和协作过滤组合,先用基于内容的推荐技术得到项目集的分类,根据分类对矩阵中的新项目进行评价预测,从而使矩阵变稠密[42], Fab[9]系统就是基于这个思想建立的。其他一些方法还包括先用初始评价矩阵的奇异值分解去得到矩阵的特征值,从而对项目进行分类,然后用神经网络等学习算法对新项目进

行评价预测，从而提高矩阵稠密度[43]。还有学者尝试用图论 Horting 的方法去解决这个问题[44]。

3. 2. 2 冷开始问题 (Cold-start)

又称第一评价问题(first rater)，或新项目问题(New-item)，从一定角度可以看成是稀疏问题的极端情况。因为传统的协作过滤推荐是基于邻居用户资料得到目标用户的推荐，在一个新的项目首次出现的时候。因为没有用户对它作过评价，因此单纯的协作过滤无法对其进行预测评分和推荐。而且，由于新项目出现早期，用户评价较少，推荐的准确性也比较差[36]。相似的，推荐系统对于新用户的推荐效果也很差。冷开始问题的极端的案例是：当一个协作过滤推荐系统刚开始运行的时候，每个用户在每个项目上都面临冷开始问题。

冷开始(cold start)问题又分为新项目问题(new item)和新用户(new user)问题。

(1)新项目问题：也被称为早期评价者问题，一个未获得足够评价的新项目不易被推荐出去。新项目问题常出现在不断增加新项目、但用户仅对其中一小部分做出评价的情况下。如果一个新项目没有人去评价它，或都不去评价它，则这个项目肯定得不到推荐，推荐系统就失去了作用，这在协作推荐技术问题上最为突出[45]。因为最早对新项目作出评价的用户并不能由此得到任何好处，这就需要推荐系统引入一些新机制来激励用户多作评价[35]。

在利用项目的内容以及用户的评分来计算项目之间的相似度基础上，提出了两种方法来解决新项目问题：一种方法是采用在新项目的邻居项目上评分的平均值作为该新项目的评分预测值。另外一种方法采用加权求和的方法[36]，即如下(3-11)公式所示：

$$P_{a,k} = \frac{\sum_{i=1}^n R_{a,i} \bullet \text{sim}(k,i)}{\sum_{i=1}^n |\text{sim}(k,i)|}$$

(3-11)

其中 n 为新项目 k 的邻居数目，sim(k,i) 为项目 k 和 i 之间的相似度。这种方法避免了计算新项目 k 的平均得分，所以适用于新项目问题。

(2)新用户问题：推荐系统中对用户的分类是依据目标用户与其它用户的比较，这种比较主要基于不断累积的用户评价，如果一个新用户从未对系统中的项目进行评价，则系统无法获知他的兴趣点，也就无法对他进行推荐。

针对新用户问题，有以下的解决方案：

①推荐最热门的项目(hotlist)给新的使用者。

②花一段时间搜集使用者的数据，待过了这一段时间后再来予以分群和推荐。如 Jester 中采用了 Gauge set 来解决冷启动问题，当一个用户新注册时，他必须输入他对这个 Gauge set 中的项目的评分。但这个方法只能解决新用户问题，

而不能解决新项目问题，而且需要用户的配合。

3.2.3 优化的协作推荐算法的提出

根据上述对协作推荐算法和基于降维的协作推荐算法的讨论和分析，下面分析传统的协作推荐算法稀疏性和冷开始问题产生的根源，并研究其解决途径。

可以看到，尽管传统的协作推荐算法的推荐效果相当显著，但是稀疏问题和冷开始问题仍是影响其性能的重要问题。其关键问题在于：协作过滤的特点是要求有很多个用户对项目进行评价后，用户才能互相帮助并协作选择项目。然而对于一个新项目，由于以往没有任何人对它作过评价，它就无法参与到评价和推荐中，因此推荐系统就失去了作用。评价的人越多，系统就越能发挥出其最大作用。所以对于一个新项目，需要研究并解决在初始情况下如何让它参与推荐和评价，使整个推荐系统朝良性循环的方向发展。

针对极端稀疏的用户--项目评价矩阵，我们采用降维的方法，即奇异值分解(SVD, Singular Value Decomposition)技术对评价矩阵进行初步的处理，首先采用SVD方法来预测未评分项目的预测值，得到一个无缺失值的评分矩阵;然后通过这个无缺失值的评分矩阵来计算用户之间的相似度，采用最近邻方法来求取实际未评分的项目的预测值。计算用户之间的相似到底选择哪一种相似度量标准来计算使得推荐质量比较高，我们在第五章会通过实验来选择合适的相似度量标准来计算。

在此，我们之所以选择SVD方法来对评价矩阵进行降维处理以获得比较理想的推荐质量和推荐效率，其理论依据如下：

1. 挖掘用户之间的潜在关系

在数据稀疏性的情况，提出SVD方法主要为了更好解决相关相似性度量标准SVD方法通过挖掘用户之间的关系，降低评价矩阵的维度，我们能发现更多潜在的评价。从评价矩阵中发现这种潜在的关系，也可以更好地解决个性化推荐系统中的同义词问题，SVD方法得到的降维矩阵比原先的矩阵具有较低的噪音，而且便于发现客户之间的关系。

此外，我们当然可以使用其它经典的协作推荐算法对用户—项目评价矩阵进行处理。最近邻方法要求不同用户之间的相似程度，但是如果两个用户之间没有都打过分的项，则他们之间的相似系数无法求取，在这种情况下其它的协作推荐算法则无法充分地挖掘客户之前的关联性。

首先采用SVD方法来预测未评分项目的预测值，得到一个无缺失值的评分矩阵;然后用这个无缺失值的评分矩阵来计算用户之间的Pearson系数，采用最近邻方法来求取实际未评分的项目的预测值。

2. SVD 方法与相关相似性度量方法的定性比较与分析

对于一个稀疏矩阵，SVD 方法的时间复杂度为 $O((m+n)^3)$ ，其计算复杂度为 $O(m^2 \cdot n)$ 。在存储空间方面，SVD 方法分别需要一个 $m \cdot k$ 和 $k \cdot n$ 的矩阵空间 $O(m+n)$ (当最近邻数为 k 时)，而对于基于相关性度量算法中，则需要 $O(m^2)$ 的矩阵存储空间，相对来讲比 $O(m+n)$ 大很多。从以上对比可知，SVD 方法降维处理后的低维矩阵的方法比相关性度量算法在预测性能方面具有更大的优势。同时，降维后的矩阵形成最近邻也比相关性度量算法快得多。

之后，我们对于新项目问题的解决办法，我们采用了上一小节 3.2.2 中所提出的中心加权求和的方法来预测项目的评估值，从而预测用户对新项目的评分。

中心加权求和的方法是基于用户评价项目的特征属性，学习用户的兴趣，因此能发现这两个项目是相似的。那么，根据相似项目的属性以及用户对相似项目的评分，可以初步预测用户对新项目的评分，这样就得到了对冷开始问题的一个解决途径，同时，稀疏性问题也可以得到有效的解决。

基于上述分析，本文提出了一种采用基于降维的推荐和项目评估预测的改进的协作过滤算法，利用基于降维的协作推荐对相似项目的研究弥补协作过滤推荐在新项目推荐方面的不足，从而有效的解决冷开始和稀疏问题。该优化推荐算法首先对用户-项目评价矩阵进行降维的预处理，发现用户之间的相似性，然后分析项目的特征属性、找出新项目的相似项目：然后通过用户对相似项目的评价来预测对新项目的评分，最后使用传统的协作过滤推荐在相似项目的范围内计算邻居用户并给出最终的预测评分，使新项目参与到推荐中。

3.3 优化的协作过滤算法

基于 3.1 节和 3.2 节的问题分析，本节介绍采用基于降维与项目评估预测的推荐改进协作过滤解决传统的协作过滤算法中的冷开始和稀疏问题，详细地描述算法的流程、步骤说明。

由于用户评分数据的极端稀疏性，传统的相似度量方法不能有效地计算目标用户的最近邻居，协作过滤推荐系统的推荐质量难以保证。为了解决用户评分数据的极端稀疏性，最简单的办法就是将用户对未评分项目的评分设为一个固定的缺省值(一般设为评分域的中间值，如在 5 分制评分中设为 3)，或者设为用户的平均评分，实验表明，这种改进方法可以有效地提高协作过滤推荐系统的推荐精度。

显然，用户对未评分项目的评分不可能完全相同，因此上述改进方法并不能从根本上解决用户评分数据极端稀疏情况下传统相似度量方法存在的问题。本算法通过计算项目间的相似度，由用户对相似项目的评分预测用户对未评分项目

的评分，使得用户之间共同评分的项目比较多，从而可以有效地解决用户评分数据极端稀疏情况下传统相似度度量方法存在的不足,使得计算得到的目标用户的




图 4-1 优化的流程图

最近邻居比较准确。

下面我们来详细介绍基于项目评估预测的协作过滤推荐算法。算法主要分为三步：对用户评价矩阵进行 SVD 方法的降维，寻找最近邻居和产生推荐。第 3.1 节给出了基于项目评分预测的邻居查找方法，第 3.2 节给出了根据最近邻居产生推荐的计算方法。

3.3.1 算法的流程图

本优化算法的流程图见上页图 4-1 所示。

3.3.2 对用户评价矩阵进行降维处理

可以根据本文 3.1.3 节中的 3.1.3 算法对输入的用户评价矩阵进行降维，生成一个新的用户评价矩阵，具体过程中以上算法中已经详细介绍，在此不做过多介绍。

3.3.3 寻找最近邻居

为了有效地解决用户-项目评阶矩在极端稀疏情况下传统的相似度度量方法不能计算用户间相似度的问题，本文提出在计算用户 i 和 j 之间的相似度时，首先计算已被用户 i 和用户 j 评分过的项目集合的并集 U_{ij} ，设经用户 i 评过分的项项目集合用 I_i 表示,则 U_{ij} 为 $U_{ij} = I_i \cup I_j$ 。

用户 i 和用户 j 在项目集合 U_{ij} 中均未评分的项目 p 可以根据用户对与其最近邻项目集合 M_p 的评分预测出来，然后在项目集合 U_{ij} 上用来计算用户 i 和用户 j 之间的相似度，从而挖掘用户 i 与用户 j 之间的相关程度。这种方法不仅能有效地解决相似性度量方法中用户共同评分数据比较少少的情况，而且可以有效地解决余弦相似性度量方法和相关相似性度量方法中对所有未评分商品的评分均相同而产生的冷启动中的新项目问题(即未被评价的项目得不到推荐)，使得计算出来的目标用户的最近邻居比较准确，从而有效地提高推荐算法的推荐质量。

预测用户 i 对项目集合 U_{ij} 中未评分项目的评分是基于项目相似度的协作过滤推荐算法的关键。设用户 i 在项目空间 U_{ij} 中未评分的项目集合用 N_i 表示，即

$$N_i = U_{ij} - I_i$$

对任意项目 $p \notin M_p$,使用如下方法预测用户 i 对项目 p 的评分 $P_{i,p}$ [37]:

- 计算项目 p 与任意除 p 项目以外的其他项目之间的相似度，与计算用户间相似度类似，首先需要得到对项目 i 和项目 j 评分的所有用户评分，然后通过第 4.1 节中介绍的各种相似度度量方法计算项目 i 和项目 j 之间的相似度。
- 将相似度最高的前 k 个项目作为项目 p 的邻居项目集合，即在整个项目空间中查找项目集合 $M_p = \{I_1, I_2, \dots, I_k\}$,使得 $p \notin M_p$ ，并且项目 I_1 与项目 p 的相似

度 $\text{sim}(p, I_1)$ 最高, 项目 I_2 与项目 p 的相似度 $\text{sim}(p, I_2)$ 次之, 依此类推, 得以形成项目 p 的 k 近邻居集合。

- 得到 M_p 后, 采用中心加权求和的方法来预测用户 i 对项目 p 的评分 $P_{i,p}$, 如公式 (3-12) 所示:

$$P_{i,p} = \overline{R_{p,n}} + \frac{\sum_{n \in M_p} \text{sim}_{p,n} \times (R_{i,n} - \overline{R_{p,n}})}{\sum_{n \in M_p} (|\text{sim}_{p,n}|)} \quad (3-12)$$

通过上述方法处理后, 用户 i 和用户 j 对项目集合 U_{ij} 中的所有项目均有评分, 即对任意的项 $p \in U_{ij}$, 用户 i 对项目 p 的评分为:

$$R_{i,p} = \begin{cases} R_{i,p}, & \text{如果用户 } i \text{ 已对项目 } p \text{ 进行了评价} \\ P_{i,p}, & \text{如果用户 } i \text{ 没有对项目 } p \text{ 进行评价} \end{cases}$$

然后基于项目集合 U_{ij} 通过第 2.1 节中介绍的 2 种相似度度量方法计算用户 i 和用户 j 之间的相似度, 在我们提出的方法中相关相似度和修正的余弦相似度是一致的, 具体为:

- 余弦相似度

$$\text{sim}(i,j) = \frac{\sum_{u \in U_{ij}} (R_{i,u} \times R_{j,u})}{\sqrt{\sum_{u \in U_{ij}} R_{i,u}^2} \sqrt{\sum_{u \in U_{ij}} R_{j,u}^2}} \quad (3-13)$$

- 相关相似度(修正的余弦相似度)

$$\text{sim}(i,j) = \frac{\sum_{u \in U_{ij}} (R_{i,u} - \overline{R_i})(R_{j,u} - \overline{R_j})}{\sqrt{\sum_{u \in U_{ij}} (R_{i,u} - \overline{R_i})^2} \sqrt{\sum_{u \in U_{ij}} (R_{j,u} - \overline{R_j})^2}} \quad (3-14)$$

寻找最近邻居的目标就是对每一个用户 u , 在整个用户空间中查找用户集合 $C = \{C_1, C_2, \dots, C_k\}$, 使得 $u \notin C$, 并且 C_1 与 u 的相似度 $\text{sim}(u, C_1)$ 最高, C_2 与 u 的相似度 $\text{sim}(u, C_2)$ 次之, 依此类推以形成用户 u 的最近邻集合 M_u , 设用户 u 的最近邻居集合用 M_u 表示。

3.3.4 产生推荐

通过本文提出的相似度度量方法得到目标用户的最近邻居, 下一步需要产生相应的推荐。则用户 u 对项目 i 的预测评分 $P_{u,i}$, 可以通过用户 u 对最近邻居集合 M_u 中项目的评分得到, 计算方法如公式 (3-15) 所示:

$$P_{u,i} = \overline{R_u} + \frac{\sum_{n \in M_u} \text{sim}(u,n) \times (R_{n,i} - \overline{R_n})}{\sum_{n \in M_u} |\text{sim}(u,n)|} \quad (3-15)$$

3.4 小结

本章讨论了协作过滤技术(包括 User-based 和 Item-based 两种算法)的基本原理,并在此基础上探讨了协作过滤技术的两大缺点,进而研究了现实的推荐系统中采用对用户评价矩阵进行奇异值分解和项目评估预测的协作过滤推荐算法来弥补单个基本协作过滤算法的不足。本章的最后,讨论了优化协作推荐算法的基本思路和策略。这一章为下两章论文的核心部分提供了一个技术方面的基础。从论文的第四章开始,就要研究基于降维和项目评估预测的协作过滤的优化协作过滤算法。

第四章 实验设计和结果分析

第三章论述了采用基于降维和项目评估预测的改进的协作过滤算法能够解决传统的协作过滤算法中的冷开始和稀疏问题的理论依据。本章在第三章的理论论述的基础上设计仿真实验并分析实验结果，主要目的是证明其推荐的准确性，说明优化协作算法的实际效果。

在实验数据方面，采用协作过滤领域的著名数据库 Jester 作为实验数据库对优化协作过滤算法进行评估。在实验设计方面，设计合理可行的实验过程和评估标准，利用具有强大矩阵运算功能的开发工具 MATLAB 编程实现算法并进行实验。在实验结果分析方面，通过对实验结果的解释和比较，表明了优化的协作过滤算法的准确性与有效性以及稳定性。

4.1 推荐的实验数据

我们采用 Jester 站点提供的数据集(<http://www.ieor.berkeley.edu/~goldberg/jester-data/>)Jester_data 数据集是一个基于 Web 的研究型推荐系统，用于接收用户对笑话的评分并提供相应的笑话推荐列表。目前,该 Web 站点的用户已经超过 430 00 人，用户评分的笑话超过 3500 部。我们从用户评分数据库中选择 6 000 条评分数据作为实验数据集，实验数据集中共包含 24983 个用户和 100 个笑话(joke)，该数据集以 Excel(.xls)格式存放一个 24983×101 的评价，表示共有 24983 个用户对 100 个笑话(joke)进行了在线评价而汇总得到的数据集。第一列表示每个用户所评价的笑话数(37—100 之间的数值)，评分数据区间在 (-10.00,+10.00) 之间，其中分值 99 表示这个笑话其对应的用户没有进行相应的评价。

为了度量整个数据集的稀疏性，我们引入稀疏等级的概念,其定义为用户评分数据矩阵中未评分条目所占的百分比。我们选择的电影数据集的稀疏等级为：

$$1-6111/(100*200)=0.6945.$$

4.2 推荐的实验设计

本节介绍优化协作过滤算法的仿真实验设计，包括评估标准和实验过程。

4.2.1 评估标准

推荐的评价也是推荐算法实验设计一个重要问题，总体上评价推荐可以有两种方法[37]：一是在线(Online)评价，二是下线(Off line)评价。上线评价是在线调查用户对推荐系统的评价。下线评价是用一个已知的数据集来评价推荐系统的性

能，目前一般采用美国数字设备公司(Digital Equipment Corporation 系统研究中心提供的专用实验数据库 Each-Movie。本文采用下线评价的方法。

平均绝对误差 MAE(Mean Absolute Error)较早的在 Shardanand & Mases 及 Sarwar 等用于评价系统预测的性能。其它的标准还有如：RMSE(Root Mean Squared Error)和 correlation between ratings and predictions 等。以上所有标准基本上都是针对预测结果的计算，所得的结论基本是相同的，因为我们只考虑 MAE 进行评价。MAE 是测试集中所有用户对资源打分的实际值与预测值的绝对值的平均。对于 N 个实际打分值-预测值对 (p_i, q_j) ,平均绝对误差 MAE 的计算公式：

$$MAE=\frac{\sum_{i=1}^N|p_i-q_j|}{N}$$

MAE 值越小说明推荐算法的预测精度越高。

Top-N 推荐质量的衡量一般采信息检索领域评价系统的标准，用准确率(Precision)和召回率(Recall)衡量：

$$\text{precision}=\frac{\text{正确推荐的项目数}}{\text{所有推荐的项目数}}=\frac{d}{b+d}$$
$$\text{recall}=\frac{\text{正确推荐的项目数}}{\text{所有有用的项目数}}=\frac{d}{c+d}$$

准确率和召回率的计算公式中的 a, b, c, d 的含义如下表 5-1 所示。

表 5-1 符号的表示含义

实际值\预测值	否 定 数	肯 定 数
否定数	a	b
肯定数	c	d

由于准确率和召回率在一定程度上是一对相对矛盾的指标，准确率高就意味着召回率低。为了平衡两者，综合评价指标 F-measure 经常被采用：

$$F\text{-measure}=\frac{2\times\text{precision}\times\text{recall}}{\text{precision}+\text{recall}}=\frac{2}{1/\text{precision}+1/\text{recall}}$$

为了控制对准确率和召回率的偏好，引入了 E-measure 指标：

$$E\text{-measure}=\frac{1}{\alpha(1/\text{precision})+(1-\alpha)(1/\text{recall})}$$

在本文的研究中，我们主要目的是衡量和比较算法的准确性。希望最后的算法能够准确的预测未评价的项目的评价分，从而为用户作出比较准确的推荐，所

以算法的精确度(Precision)是评价推荐算法的一个主要指标。像大多数文献的做法一样，我们以预测值和真实值的平均绝对误差(MAE:Mean Absolute Error)作来衡量算法精确度。

4.2.2 实验结果及分析

1.实验结果

首先对各种不同的相似度量标准进行试验，选择最佳的相似度量标准；然后在相同的数据集上进行对比实验，比较基于项目评估的协作优化算法与经典的协作过滤算法的推荐质量，并对实验室结果进行分析。

2. 相似性度量标准比较

在计算项目之间的相似性时，由于余弦相似度量方法比较容易实现，预测速度比较快，而且预测精度也比较高，所以本文选择余弦相似性作为项目之间的相似性的度量标准。

在协作优化算法中，修正的余弦相似性度量方法与相关相似性度量方法一致，统称为相关相似性。原始的余弦相似性称为余弦相似性，以这两种相似性度量方法分别对数据集进行实验计算其 MAE，邻居个数从 4 增加到 20，间隔数为 4。实验结果如上图 5-1 表示。




图 5-1 相似性度量标准比较

从上图可知，在相同的实验条件下，相关相似性度量方法的 MAE 均低于相余弦相似性度量方法，可见，使用相关相似性度量方法的推荐质量要高于余弦相

似性度量方法。

3. 推荐精度比较

为了检验协作优化算法的有效性，以传统的 User-based 协作过滤推荐算法和 Item-based 协作过滤算法为参照，而且分别以余弦相似性和相关相似性作为相似度量标准，计算其 MAE，邻居个数从 4 增加到 20，间隔数为 4，然后与协作优化的推荐算法作比较，实验结果如下图 5-2 所示。




图 5-2 优化算法与基于用户、基于项目的协作算法的比较

从上图 5-2 所示，可以看出，在相同的用户-项目评价矩阵，相同度量方法的条件下，相同邻居数的条件下，使用了降维和中心加权方法的优化协作过滤算法比传统的 User-based 协作过滤推荐算法和 Item-based 协作过滤算法的推荐精度都要高很多，而且从图中还可以看出，当邻居数大于 8 时，推荐质量趋于稳定，从而体现了本优化协作过滤算法具有比前两者算法更好的稳定性和健壮性。

4. 试验结果分析

基于降维和中心加权求和的协作优化算法与传统的协作推荐算法最大的不同就在于寻找最近邻居的方法不一样。在传统的协作过滤推荐算法中，如果采用相关相似性，两个用户之间的相似性由用户共同评分过的项决定，在用户评分数据极端稀疏的情况下，两个用户共同评分过的项目非常少，经常只有一到两个项，用户即使在这些项上的评分非常的相似，也不一定是最近邻居，实验结果表明这种相似性度量方法的推荐质量最低。如果采用余弦相似性，则用户对所有未评分项的评分均相同(均为 0)，这显然也是不精确的。

由实验结果可知,这种相似性度量方法的推荐质量比余弦相似性度量方法更好。在基于降维的协作优化算法中,首先通过项目之间的相似性初步预测用户对未评分项目的评分,使得用户之间共同评分过的项目比较多,然后通过余弦相似性度量方法计算用户之间的相似性,实验结果证明,这种优化算法的推荐质量得了有效的提高。

4.3 小结

本章提出了一个基于降维和项目评估预测的协作优化算法。在大型电子商务系统中,用户数目和项目数目急剧增加,导致用户评分数据的极端稀疏性,在用户评分数据极端稀疏的情况下传统相似性度量方法存在各自的弊端,导致计算得到的目标用户的最近邻居不准确,推荐系统的推荐质量急剧下降。针对用户评分数据的极端稀疏性,我们详细分析了传统的相似性度量方法存在的问题,提出了基于降维和项目评分预测的协作优化算法,这个优化算法首先对用户-项目评价矩阵进行降维的数据预处理,然后通过计算项目之间的相似性,初步预测用户对未评分项目的评分,然后采用一种新颖的相似性度量方法—中心加权求和的方法来计算用户的最近邻居。实验结果表明,这种优法算法可以有效地解决用户-项目评分矩阵的数据极端稀疏情况下传统相似性度量方法存在的不足,显著地提高推荐系统的推荐质量。

第五章 总 结

5.1 本文的工作

电子商务的发展,使得数据量以惊人的速度增长,为获取有价值的信息,电子商务推荐系统针对不同的用户,对产品和服务作出个性化推荐。协作过滤方法已经成功地应用于电子商务推荐系统,但是随着电子商务推荐系统的广泛应用与系统规模的不断扩大,协作过滤算法也暴露出一些问题与挑战,主要包括推荐质量、数据稀疏性、冷开始问题等

本文在第三章讨论了 User-based 协作过滤推荐算法、Item-based 协作过滤推荐算法,并分析和讨论了两种协作推荐算法存在的不足及其相对应的优化算法。在以上的分析的基础上,本文主要研究成果是提出了协作过滤推荐算法的改进算法:

- 1) 通过奇异值分解(SVD, Singular Value Decomposition)的方法对用户评价矩阵进行矩阵分解,挖掘出用户之间的潜在关联性;
- 2) 在 SVD 降维的数据预处理的基础上,我们根据项目之间的相似度初步预测用户对未评分项目的评分,并在此基础上采用中心加权求和的相似度度量方法来计算目标用户的最近邻居;
- 3)最后,利用用户的最近邻居集合,预测对每个项目的评分,产生推荐给目标用户。

通过其仿真与测试验证了改进算法的合理性和有效性,从而可以有效弥补用户-项目评价矩阵数据极端稀疏和冷开始情况下传统协作过滤推荐方法存在的不足,有效地提高了电子商务推荐算法的推荐质量。

5.2 进一步的工作

电子商务个性化推荐系统是个新的研究与应用领域,目前,国内对电子商务推荐系统的研究,无论在理论研究上还是在实践应用上,相对于国际水平来说都很滞后。本文对协作过滤推荐方法进行了深入的研究和探讨,今后将在以下几个方面进行有益的研究和探索:

- 1)将协作推荐算法与基于内容的推荐算法有效地结合起来,进一步有效地解决好冷开始问题、数据稀疏性等问题。
- 2)推荐系统实时性与推荐质量之间平衡问题的研究。
- 3)结合本实验室的旅游推荐系统,对电子商务推荐系统的体系构架的研究。

5.3 研究展望

个性化推荐研究是一个新兴的领域，尽管目前已取得了很好的研究成果，但还存在很多问题，如在数据获取主要依赖用户的显式评价，自动获得用户的隐式信息方面做得不够；过分集中对协作推荐研究方面，同时对稀疏问题及冷开始问题等经典问题缺乏有效的解决方法；对推荐系统的开发与应用，尤其是与企业其它系统的集成应用研究不够；推荐技术应用集中在网上购物，没有把推荐技术运用到其它行业等。未来个性化推荐研究应有以下热点与方向：

(1)对推荐算法的进一步改进，提高推荐算法的运算性能及实时性，以使得推荐系统能产生更加精确、实时的推荐。尽管目前对协作过滤技术研究很多，但实际效果并不是很理想，尤其在处理稀疏和冷开始问题上缺乏真正有效的方法，同时随着 Internet 的普及，用户评价数据库不断增大，对推荐算法的运算性能提出新要求，要求提高推荐算法的速度，加强推荐算法的实时性，同时提高推荐的准确性。目前个性化推荐系统没有真正普及，尤其在一些价格相对贵重的产品，用户并不使用个性化推荐系统，主要原因就是目前推荐系统推荐的准确度并不高，用户不是很依赖推荐系统。

(2)坚持以客户为中心的推荐研究，要从单一客户推荐的研究转向支持客户群推荐。目前的推荐系统都是支持单一用户的个性化推荐，未来推荐系统应该支持多用户推荐，包括为某用户群作出推荐、用户群之间互相推荐，主要研究的问题是用户群之间、用户之间如何实现兴趣资料信息共享，推荐算法模型的设计等问题。

(3)将电子商务推荐系统由虚拟的销售人员转变为市场分析工具。目前电子商务推荐系统主要面向用户的，未来电子商务系统应除为用户作出个性化推荐服务外，还应增强其市场分析能力。

(4)开发销售方的电子商务推荐系统，为商家的产品定价、促销活动及交叉销售等提供推荐。为增强推荐系统的功能，未来电子商务推荐系统应集成企业销售系统、客户关系管理系统、供应链系统等企业信息系统，共同为企业的产品定价、销售等提供决策支持。

参考文献

- [1] Goldberg D, Nichols D, Oki B M, Terry D. Using Collaborative Filtering to Weave an Information Apestry. In Communications of the ACM, 35(12), 1992.
- [2] J Konstan, B Miller, D Maltz, J Herlocker, L Gordon, J Riedl. GroupLens: Applying Collaborative Filtering to Usenet News. In Communications of the ACM, 40(3):77-87, 1997.
- [3] Resnick P, Iacovou N, Suchak M, Bergstrom P, Riedl J. GroupLens. An Open Architecture for Collaborative Filtering of Netnews. In Proceedings of the Conference on Computer Supported Cooperative Work, Chapel Hill, NC, 175-186, 1994.
- [4] U Shardanand, P Maes. Social Information Filtering: Algorithms for Automating of Mouth'. In Proceedings of the ACM CHI Conference (CHI'95), 1995.
- [5] Hill W, Stead L, Rosenstein M, Fumas G. Recommending and Evaluating Choices in a Virtual Community of Use. In CHI '95: Conference Proceedings on Human Factors in Computing Systems, Denver, CO, 194-201, 1995.
- [6] Resnick, Varian. Recommender systems. In Communications of the ACM, 40(3): 56-58, 1997
- [7] Chant C Aggarwal, Joel L Wolf, Kun-Lung Wu, Philip S Yu. Horting Hatches an Egg: A New Graph-theoretic Approach to Collaborative Filtering. In Proceedings of ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, 1999.
- [8] Johns Breese, David Heckerman, Carl Kadie. Empirical Analysis of Predictive Algorithms for Collaborative filtering. In Proceedings of the 14th Conference on Uncertainty in Artificial Intelligence, 43-52, 1998.
- [9] Marko Balabanovic, Yoav Shoham. FAB: Content-based Collaborative Recommendation. In Communications of the ACM, 40(3), March 1997.
- [11] Loren Terveen, Will Hill, Brian Amento, David McDonald, PHOAKS. A System for Sharing Recommendations. In Communications of the ACM, 40(3):59-62, 1997.
- [12] Schafer J B, Konstan J, Riedl J. Recommender Systems in E-Commerce. In EC '99 Proceedings of the First ACM Conference on Electronic Commerce, Denver, CO, 158-166, 1999.
- [13] Good N, Schafer J B, Konstan J A, Borchers A, Sarwar B, Herlocker J, Riedl J. Combining Collaborative Filtering with Personal Agents for Better Recommendations.

In Proceedings of the Sixteenth National Conference on Artificial Intelligence (AAAI-99), 439-446, 1999.

[14] Sarwar B M, Konstan J A, Borchers A, Herlocker J, Miller B, Riedl J. Using Filtering Agents to Improve Prediction Quality in the GroupLens Research Collaborative Filtering System. In Proceedings of CSCW '98, Seattle, WA, 1998.

[15] Billsus D, Pazzani M. Learning Collaborative Information Filters, In Proceedings of the International Conference on Machine Learning (Madison WI, July 1998), Morgan Kaufmann Publisher.

[16] Sarwar B M, Karypis G, Konstan J A, Riedl J. Analysis of Recommendation Algorithms for E-Commerce. In Proceedings of the ACM EC'00 Conference. Minneapolis, MN.158-167, 2000.

[17] Prem Melville, Raymond J. Mooney, Ramadass Nagarajan. Content-Boosted Collaborative Filtering for Improved Recommendations, Department of Computer Sciences, University of Texas Austin, TX 78712.

[18] Pazzani M J. A Framework for Collaborative, Content-Based and Demographic Filtering. Artificial Intelligence Review, 13 (5/6): 393-408, 1999.

[19] Cotter P, Smyth B. PTV: Intelligent Personalized TV Guides. In Twelfth Conference on Innovative Applications of Artificial Intelligence, 957-964, 2000.

[20] Claypool M, Gokhale A, Miranda T. Combining Content-based and Collaborative filters in an online newspaper. In Proceedings of the SIGIR-99 Workshop on Recommender Systems: Algorithms and Evaluation, 1999.

[21] R D Lawrence, G S Almasi, V Kotlyar, M S Viveros, S S Duri. Personalization of Supermarket Product Recommendations, In IBM Research Report, 2000.

[22] J Ben Schafer, Joseph A Konstan, John Riedl. E-Commerce Recommendation Applications, University of Minnesota, 2001.

[23] Pazzani M, and Billsus D. Learning and Revising User Profiles: The Identification of Interesting Web Sites. In Machine Learning, 27:313-331, 1997.

[24] Basu Chumki, Haym Hirsh, William Cohen. Recommendation as Classification: Using Social and Content-based Information in Recommendation[C]. Proceedings of AAAI'98, 1998. 714-720.

[25] Billsus Daniel, Michael J Pazzani. Learning Collaborative Information Filters[C]. Proceeding of ICML'98, 1998. 46-53

[26] Breese John S, David Heckerman, Carl Kadie. Empirical Analysis of

Predictive Algorithms for Collaborative Filtering[C].Proceedings of UAI'98,1998.43-52

[27] Sarwar Badrul,George Karpis,Joseph Konstan,et al.Riedl. Analysis of Recommendation Algorithms [Z].www10,2001

[28]Schafer J Ben,Joseph A Konstan,John Riedl.E-commerce Recommendation Application.Journal of Data Mining and Knowledge Discovery,January-April 2001,Vol5:115-153.

[29] 韩家玮,坎伯.数据挖掘---概念与技术[M].北京 机械工业出版社

[30] Lang, K.: 1995, Newsweeder: Learning to filter news. In: Proceedings of the 12th International Conference on Machine Learning, Lake Tahoe, CA, pp. 331-339.

[31] Pazzani, M. J., A Framework for Collaborative, Content-Based and Demographic Filtering. Artificial Intelligence Review, 13 (5/6), 393-408, 1999.

[32] Schmitt, S. and Bergmann, R.: 1999, Applying case-based reasoning technology for product selection and customization in electronic commerce environments. 12th Bled Electronic Commerce Conference. Bled, Slovenia, June 7-9, 1999.

[33] Krulwich, B:1997, Lifestyle Finder: Intelligent User Profiling Using Large-Scale Demographic Data. Artificial Intelligence Magazine 18 (2),37-45.

[34] Brin, S. and Page, L.: 1998, The anatomy of a large-scale hypertextual {Web} search engine.Computer Networks and ISDN Systems, 30(1-7),107-117.

[35] ROBIN B. Hybrid recommender systems : survey and experiments [R] . Department of Information Systems and Decision Sciences, California State University , Fullerton.

[36] Sarwar,B. M., Karypis, G., Konstan, J. A., and Riedl, J. Application of Dimensionality Reduction in Recommender System-A Case Study. In ACM WebKDD 2000 Workshop, 2000.

[37] Sarwar, B., Karypis, G, Konstan, J., and Reidl, J. Item-based Collaborative Filtering Recommendation Algorithms. In Proceedings of the Tenth International World Wide Web Conference on World Wide Web, 2001.

[38] Deerwester, S., Dumais, S. T., Fumas,G.W., Landaue, T. K., and Harshman, R. Indexing by Latent Semantic Analysis. Journal of the American Society for Information Science, 1999.

[39] Herlocker J L, Konstan J A, Borchers A, et al. An Algorithmic Framework for Performing Collaborative Filtering[C]. Proceedings of ACM SIGIR'99, ACM press, 1999. 23022371.

- [40] Sarwar B M, Karypis G, et al. Application of Dimensionality Reduction in Recommender Systems: A Case Study [C]. ACM WebKDD WebMining for E2commerceWorkshop, 2000. 114-121.
- [41] Badrul Sarwar, George Karypis, Joseph Konstan, and John Ridel. Analysis of Recommendation Algorithms for E-Commerce. In Proceedings of the ACMEC'00 Conference. Minneapolis, MN, pp. 158-167.
- [42] Good, N, Schafer, J.B., Konstan, J, Borchers, A, Sarwar, B, Herlocker, J, and Riedl, J. Combining Collaborative Filtering with Personal Agents for Better Recommendations, in Proceedings of AAAI'99 (July 1999).
- [43] Billsus, D.&Pazzani, M. Learning Collaborative Information Filters, in Proceedings of the International Conference on Machine Learning (Madison WI, July 1998), Morgan Kaufmann Publishers.
- [44] Aggarwal, C.A., Wolf, J.L., Wu, K-L., and Yu, P.S. Horting Hatches an Egg: A New Graph-Theoretic Approach to Collaborative Filtering, in Proceedings of ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 1999.
- [45] 余力,刘鲁,罗掌华 我国电子商务推荐策略的比较分析[J].系统工程理论与实践 2004.(08):p96-101.
- [46] 黎星星, 黄小琴, 朱庆生 电子商务推荐系统研究[J].计算机工程与科学, 2004. 26(5): p. 7-10.
- [47] Badrul Sarwar, George Karypis, Joseph Konstan, and John Riedl. Item-based collaborative filtering recommendation algorithm [C], Proceedings of the Tenth International World Wide Web Conference, pp.285-295, ACM Press,2001.
- [48] J A Konstan and J Riedl. Research Resources for Recommender Systems. In CHI'99 Workshop Interacting with Recommender Systems, 1999

致 谢

马上就要毕业了，回首在北京邮电大学的三年学习生活，感慨万千！

首先，感谢我的指导教师王枫教授，是她指导我完成三年学业。从论文的选题、构思、材料的收集直到论文的修改和定稿过程中，导师都给予我很大的帮助。王枫教授深厚的理论功底和认真求实的工作作风，令我受益终生，王教授渊博的学识和严谨的治学态度是我今后在学习和工作中学习的榜样。

同时，感谢李睿凡老师、周延泉老师、郭燕慧老师等三年来对我专业知识的传授，在学业上给予我的巨大支持和鼓励。

在我的论文写作过程中，得到了好朋友王一川的大力支持，在此对他表示感激，同时感谢在研究生期间所有关心、支持我的朋友们！

最后，我向我的妈妈和哥哥表示深深地感谢，无论我做什么选择，他们总是一如既往的支持我，爱护我！

攻读学位期间发表的学术论文发表的论文

1.第一作者 决策树的优化算法 发表于计算机工程（EI 检索源） 07 年 9 月发表