

文章编号:1007-757X(2024)09-0001-04

基于协同过滤和特征工程的图书推荐系统研究及云图构建

孟文杰, 孙晓瑜, 王政凯, 张雪松
(中国石油大学(华东), 图书馆, 山东, 青岛 266580)

摘要: 面向图书馆联机公共目录检索(OPAC)系统,提出一种基于协同过滤结合特征工程的加权图书推荐算法。所提算法运用协同过滤的思想,通过分析图书借阅历史,对兴趣相似的用户进行聚类。引入图书借阅次数、上架时间、排架相邻度、专业相关度等特征项,经过特征编码后,利用加权算法计算出图书推荐指数。此外,针对推荐系统的冷启动和稀疏性问题,提出解决策略。测试结果表明,所提算法实现了完整的图书推荐系统及推荐图书的云图构建。

关键词: 联机公共目录检索; 协同过滤; 特征工程; 图书推荐; 云图

中图分类号: TP391

文献标志码: A

Research on Book Recommendation System and Cloud Visualization Construction
Based on Collaborative Filtering and Feature EngineeringMENG Wenjie, SUN Xiaoyu, WANG Zhengkai, ZHANG Xuesong
(Library, China University of Petroleum (East China), Qingdao 266580, China)

Abstract: This paper proposes a weighted book recommendation algorithm for online public access catalogues (OPAC) system, by combining collaborative filtering with feature engineering. The algorithm applies collaborative filtering to cluster users with similar interests by analyzing the borrowing history. The book recommendation index is calculated by weighted algorithm after the feature code is introduced, such as the number of books borrowed, shelf time, shelving adjacency and professional relevance. In addition, the solutions to the problems of cold start and sparsity are proposed. The test results show that the proposed algorithm realizes the complete book recommendation system and the cloud visualization construction of recommended books.

Key words: online public access catalogue; collaborative filtering; feature engineering; book recommendation; cloud visualization

0 引言

联机公共目录检索(OPAC)系统是图书馆与读者交互的终端系统^[1]。随着大数据时代到来,如何使 OPAC 系统在读者进行图书检索的时候,变“被动服务”为“主动服务”,想读者之所想,为读者提供精准的图书推荐,是当前图书馆信息服务面临的重要课题之一。

目前的图书推荐系统研究大多基于读者画像^[2-4],需要在获取当前登录读者信息的前提下进行图书推荐,但是很多图书检索行为是在读者未登录 OPAC 系统状态下完成的,因此基于读者画像的推荐算法就不再适用。本文面向 OPAC 系统,聚焦非登录状态的读者检索行为,提出一种基于特征工程和协同过滤的加权图书推荐算法并完成系统构建。通过深入挖掘图书的借阅历史,揭示读者之间潜在的兴趣相似性,以实现更为准确的图书推荐。同时,针对推荐系统的冷

启动和稀疏性问题提出相应的解决策略。此外,本文引入云图构建技术,以直观地展现图书之间的潜在关联,为读者提供一个全面了解领域知识结构的视角。

1 基于协同过滤和特征工程的图书推荐算法

推荐算法是图书推荐系统的核心。本文基于协同过滤算法的基本思想^[3,5],利用读者借阅行为数据和借阅图书的相似度进行推荐。同时,引入特征工程,通过特征选择和特征编码,将原始数据转化为适合模型使用的特征矩阵,提高推荐模型的性能和泛化能力。通过加权计算得到图书的推荐指数,并根据指数高低进行图书推荐。算法流程如图 1 所示。

1) 构建相似用户集合

针对 OPAC 系统中读者检索的目标图书,通过分析该图书的历史借阅记录,筛选出近 4 年借阅过该图书的用户,形

基金项目:国家自然科学基金(51874340);教育部产学研合作协同育人项目(202102020019);青岛市社会科学规划研究项目(QDSKL2301043)

作者简介:孟文杰(1982—),女,硕士,馆员,研究方向为智慧图书馆;

孙晓瑜(1981—),女,硕士,副研究馆员,研究方向为信息资源服务;

王政凯(1986—),男,硕士,馆员,研究方向为信息技术;

张雪松(1982—),男,硕士,副研究馆员,研究方向为信息资源建设。

成用户集合 U 。这一过程是要找到对当前图书感兴趣的相似用户群体。




图1 算法流程

2) 获取相似用户借阅图书集合

深入挖掘相似用户集合 U 中用户近 4 年的借阅情况, 获取借阅图书集合 B 。通过这一关键步骤, 获取与当前用户拥有相似兴趣的其他用户感兴趣的全部图书信息。

3) 特征选择

基于相似用户借阅图书集合 B , 特征维度设定为四元组, $features = (\text{借阅次数}, \text{图书上架时间}, \text{图书相邻度}, \text{专业相关度})$ 。

(1) 借阅次数。借阅次数为相似用户借阅某本图书的总次数。该参数值越高, 表示相似用户集合对该图书感兴趣的程度越高, 当前读者对该图书感兴趣的可能性也就越大, 对图书推荐结果有着极其重要的影响。

(2) 图书上架时间。图书上架时间的数据对象是新上架图书。对于上架时间在 1 年内的图书, 根据上架时间段给予一个量化评分, 图书上架时间越短, 赋值越高。若该图书上架时间已经超过 1 年, 则赋值为 0。

(3) 图书相邻度。读者借阅某本图书时有很大概率对同一书架上与该图书相邻的图书也感兴趣。因此, 将图书相邻度作为特征项加入量化矩阵。相邻度依据中图分类法确定, 在实际馆藏中, 若集合 B 中的图书与当前图书在同一个书架上, 则依据相邻远近进行量化评分, 距离当前图书越近, 赋值越高, 不在同一书架上的图书则赋值为 0。

(4) 专业相关度。专业相同或者类似的人在借阅偏好上一致性的概率更高, 尤其是学科专业类的图书, 因此引入专业相关度。若矩阵中的图书与当前图书为相同或者相似专业背景参考用书, 则根据相关度进行量化评分, 否则为 0。

4) 特征编码

为了在算法中更有效地表达特征, 提高特征提取效率, 需要进行特征编码以适应机器学习模型的输入。采用 Min-Max Scaling 归一化方法, 将特征值映射到 $[0, 1]$ ^[6], 具体公式为

$$f(x) = \begin{cases} 0, & x_{\max} = x_{\min} \\ \frac{x - x_{\min}}{x_{\max} - x_{\min}}, & x_{\max} \neq x_{\min} \end{cases} \quad (1)$$

式(1)中: $x_{\max}$ 与 $x_{\min}$ 分别为特征属性最大值与最小值; x 为

当前属性值; $f(x)$ 为经过特征编码后的属性值。

5) 构建特征矩阵

对图书集合 B 中的每条图书信息按照特征项进行向量化表示, 则每条向量有 4 个维度, 集合 B 特征矩阵表示为

$$B = \begin{bmatrix} b_{11} & b_{12} & b_{13} & b_{14} \\ b_{21} & b_{22} & b_{23} & b_{24} \\ \vdots & \vdots & \vdots & \vdots \\ b_{n1} & b_{n2} & b_{n3} & b_{n4} \end{bmatrix} \quad (2)$$

式(2)中: n 为集合 B 中图书数量; b_{ij} ($1 \leq i \leq n, 1 \leq j \leq 4$) 为图书集合 B 中的第 i 本图书的第 j 个特征项属性值。

构建权重向量 w , 其中, w_j ($1 \leq j \leq 4$) 表示集合 B 中第 j 个特征项的权重, 如式(3):

$$w = \begin{bmatrix} w_1 \\ w_2 \\ w_3 \\ w_4 \end{bmatrix} \quad (3)$$

6) 计算图书推荐指数

图书推荐指数(BRS)用列向量 s 表示, 定义 s 由矩阵 B 乘以列向量 w 计算得出, 即 $s = B \cdot w$, 具体计算方法表示为

$$\begin{bmatrix} s_1 \\ s_2 \\ \vdots \\ s_n \end{bmatrix} = \begin{bmatrix} b_{11} & b_{12} & b_{13} & b_{14} \\ b_{21} & b_{22} & b_{23} & b_{24} \\ \vdots & \vdots & \vdots & \vdots \\ b_{n1} & b_{n2} & b_{n3} & b_{n4} \end{bmatrix} \begin{bmatrix} w_1 \\ w_2 \\ w_3 \\ w_4 \end{bmatrix} \quad (4)$$

式(4)中, s_i ($1 \leq i \leq n$) 为集合 B 中第 i 本图书的推荐指数。

7) 冷启动与稀疏性问题

在推荐算法研究领域, 冷启动和数据稀疏性问题一直是两大挑战^[7]。一方面, 当新图书上架时, 由于缺乏历史借阅数据, 容易出现冷启动问题, 需要修正推荐算法以做出合理化推荐; 另一方面, 有些图书与用户之间的交互数据相对稀疏, 导致推荐模型难以准确学习到用户兴趣。为此, 提出修正策略来增强推荐系统的建模能力。

(1) 冷启动

针对冷启动问题, 设计以下修正策略。

基于图书属性推荐: 对于新上架的图书, 通过分析图书的属性(分类、作者、出版社等), 向用户推荐具有相似属性的热门图书。

相邻图书推荐: 在用户检索某本图书时, 集合 B 为空, 即没有读者借阅过该图书, 恰恰说明当前读者的需求非常明确。这种情况下, 通过挖掘书架上的空间关系, 直接把书架上的相邻图书以及相同作者的图书推荐给读者。

(2) 稀疏性

针对稀疏性问题, 设计以下修正策略。

构建相似用户集合: 针对每本图书, 寻找近 4 年借阅过该图书的相似用户集合, 通过挖掘借阅行为的相似性, 构建用户之间的关系网络, 弥补数据中的稀疏性。

构建特征矩阵: 通过分析相似用户集合的借阅行为, 构建特征矩阵, 能够更好地理解用户对图书的兴趣, 修正数据的稀疏性。

2 系统实现及云图构建

2.1 系统实现

基于提出的图书推荐算法, 设计实现了完整的图书推荐

系统,该系统嵌入图书馆 OPAC 系统的图书详情页面,以云图形式呈现给读者,使得读者在查看当前图书信息的同时,可以直接获取系统推荐的相关图书。系统设计实现方法如下。

2.1.1 系统运行环境

服务器为 CentOS 7、Windows Server 2016;后台开发语言为 Java;前端实现为 JSP;Web 服务器为 Tomcat。

2.1.2 系统架构

推荐系统采用分层架构,将系统划分为数据存储层、推荐引擎层和读者交互层 3 个层次。数据存储层存储和处理系统所需的所有数据;推荐引擎层实现本文提出的推荐算法,为用户生成个性化图书推荐指数并生成推荐云图;读者交互层处理读者与推荐系统的交互,将推荐可视化结果在 OPAC 前台呈现给读者。系统架构如图 2 所示。




图 2 系统框架图

2.1.3 数据来源

系统数据来源为中国石油大学(华东)图书管理系统(汇文文献信息服务系统 5.5)的 Oracle 数据库,主要原始数据如表 1 所示。

表 1 原始数据表

表名	详细描述
MARC	存储图书 marc 数据,包括作者、出版社等信息
CALL_NO_LST	存储图书索书号
ITEM	存储图书可流通复本数据
READER	存储读者数据,包括学号、姓名、专业等信息
READER_CERT	存储读者证件数据,包括有效期等信息
LEND_LST	存储在借图书数据
LEND_HIST	存储历史借阅数据

由于原始数据集数据量过于庞大,且推荐系统为实时在线推荐图书,因此直接读取原始数据存在 2 个主要问题:加重服务器负担,导致服务不稳定,影响读者服务体验;服务器负担过重,算力不足,导致推荐系统运行效率低。为了解决上述问题,对信息服务系统的原始业务数据进行 ETL(抽取、转换、加载)处理^[8],通过清洗、转换和加载原始数据,生成推荐系统可用的数据集。数据集合为 reader_info(表 2)、book_info(表 3)和 lend_info(表 4),分别存储读者基本信息、图书基本信息和图书借阅信息。

表 2 读者基本信息表

字段	详细描述
CERT_ID	读者学号/工号
NAME	读者姓名
DEPT	读者单位/学院
OCCUPATION	读者专业
GRADE	读者年级
CLASS	读者班级
TYPE	读者类型

表 3 图书基本信息表

字段	详细描述
MARC_REC_NO	图书 marc 记录号
M_CALL_NO	图书索书号
M_TITLE	图书书名
M_AUTHOR	图书作者
IN_DATE	图书上架时间

表 4 图书借阅信息表

字段	详细描述
CERT_ID_F	读者学号/工号
MARC_REC_NO_F	图书 marc 记录号
CALL_NO	图书索书号
LEND_DATE	图书借出时间

2.1.4 云图构建及系统可视化展示

云图,作为网络流行的传播方式,通过“云层”和“渲染”,会使推荐值较高的“图书”在视觉瞬间上吸引读者的目光,从而提高推荐系统的关注度和有效性。系统中的云图构建采用 ECharts 可视化图表库^[9],通过推荐书名字体的大小和颜色的变化,生动准确地展示系统推荐的图书,使得用户界面更具吸引力,提升用户对图书推荐结果的兴趣和接受度。

推荐系统可视化实现效果如图 3 所示。

3 系统运行测试结果

推荐系统经过 3 个月的测试运行,运行数据如表 5 所示。




图 3 系统可视化效果图

表 5 运行结果数据表

图书类型	中图分类号	图书详情页面	推荐云图点	推荐系统
		点击量/次	击量/次	点击率/%
科技类图书	N~X	127 326	19 481	15.3
社科类图书	A~H,K,Z	87 932	10 288	11.7
文艺类图书	I,J	132 650	11 806	8.9
合计	A~Z	347 908	35 897	10.3

由表 5 可以看出,推荐系统在不同图书类型下都取得了显著的点击率,推荐图书的综合点击率达到 10.3%。这一数值表示,当读者在图书详情页面获取推荐云图后,有 10.3% 的推荐图书成功引起了读者的兴趣,并促使其进一步点击查看和深入了解。这一高点击率验证了推荐系统在匹配用户阅读兴趣与潜在需求方面取得了有成效的结果,表明推荐系统的推荐算法和云图构建的结合在一定程度上能够满足用户的检索需求,提高用户的资源发现效率。

4 总结

通过图书推荐为读者提供更好的服务,是大数据时代图书馆提高读者满意度的必然选择。本文基于协同过滤和特征工程的思想,提出了一种加权图书推荐算法,并结合云图构建技术,实现了推荐系统的可视化展示,为图书馆 OPAC 系统的改进和优化提供了有益的思路。通过系统的实现和运行效果分析,推荐结果获得了显著的点击率,证明了所提算法在一定程度上能够满足用户深层次的信息检索需求。然而,推荐系统仍然面临一些挑战,如何结合机器学习更精

准地缩小相似用户集合、提取更准确挖掘读者偏好的特征项、提升用户体验是下一步的研究方向。

参考文献

[1] 高洪臻. 基于杰卡德相似系数的 OPAC 用户检索行为研究[J]. 图书馆研究与工作, 2022(6): 74-79.

[2] 潘文佳, 费立美. 基于用户画像的图书推荐算法实证研究[J]. 四川图书馆学报, 2024(1): 35-39.

[3] 王大阜, 邓志文, 贾志勇, 等. 基于用户画像的高校图书馆个性化图书推荐研究[J]. 河南师范大学学报(自然科学版), 2022, 50(3): 95-103.

[4] 柳益君, 何胜, 吴智勤, 等. 基于用户社交网络分析的高校图书馆主题多样性阅读推荐[J]. 图书情报工作, 2018, 62(8): 67-73.

[5] 江水. 基于协同过滤技术推荐系统的探究[J]. 计算机技术与发展, 2021, 31(11): 1-7.

[6] 徐丞. 基于深度学习的网络 Web 异常流量检测方法[J]. 微型电脑应用, 2023, 39(12): 151-154.

[7] 孟祥福, 霍红锦, 张霄雁, 等. 个性化新闻推荐方法研究综述[J]. 计算机科学与探索, 2023, 17(12): 2840-2860.

[8] 李玉平. ETL 数据治理在高校信息化建设中的运用[J]. 无线互联科技, 2022, 19(3): 109-110.

[9] 李强, 王彬彬. 基于 Echarts 的神经网络教学系统设计与实现[J]. 无线互联科技, 2023, 20(13): 87-90.

(收稿日期: 2024-01-24)